

UNIDAD 8: DATAWAREHOUSE

Módulo profesional:
Análisis de grandes datos (Big Data)

Índice

RESUMEN INTRODUCTORIO.....	5
INTRODUCCIÓN.....	6
CASO INTRODUCTORIO	7
1. CONCEPTO	8
1.1 Definición del data warehouse.....	10
1.2 Evolución de data warehouse	11
1.3 Por qué surgió el data warehouse	17
1.3.1 Tendencias de los datos: Volumen, variedad y velocidad	18
1.3.2 Tendencias en materia de presentación de informes y análisis ..	22
1.3.3 Las nuevas tecnologías son imprescindibles para cualquier almacén de datos moderno.....	25
1.4 Arquitectura de un data warehouse	27
1.5 Importancia de data warehouse	28
1.6 Limitaciones de data warehouse	29
1.7 Esquemas de data warehouse	30
1.7.1 Esquema de estrella.....	31
1.7.2 Esquema de copo de nieve (snowflake)	33
1.7.3 Esquema de galaxia	34
1.8 Criterios de selección de un data warehouse.....	35
1.8.1 Satisface las necesidades actuales y futuras.....	36
1.8.2 Almacena e integra todos los datos en un solo lugar.....	36
1.8.3 Apoya las habilidades, herramientas y conocimientos existentes	37
1.8.4 Ahorrar dinero a la organización.....	38
1.8.5 Proporciona resitencia, tolerancia y recuperación de datos.....	39
1.8.6 Asegura los datos en reposo y en tránsito.....	40
1.8.7 Agiliza la línea de datos	41
1.8.8 Optimizar el tiempo de valorización	42
1.8.9 Evaluando el coste/valor del tiempo.....	43
1.9 Comparación de soluciones de almacenamiento de datos en la nube	43
1.9.1 Comprensión de los enfoques del almacenamiento de datos en la nube.....	44
1.9.2 Comparando arquitecturas	46
1.9.3 Evaluación de la gestión de la diversidad de datos	47
1.9.4 Elasticidad.....	48

1.9.5 Comparación de las capacidades de concurrencia.....	49
1.9.6 Garantizar el uso de SQL y otras herramientas	49
1.9.7 Verificar que ofrece soporte para el respaldo y la recuperación..	50
1.9.8 Verificar la resistencia y la disponibilidad	50
1.9.9 Optimizar el rendimiento.....	52
1.9.10 Evaluación de la seguridad de los datos en la nube.....	53
1.9.11 Costes de la administración	54
1.9.12 Habilitar el intercambio seguro de datos	55
1.9.13 Permitir la replicación de datos a nivel mundial	56
1.9.14 Asegurar el aislamiento de la carga de trabajo.....	56
1.9.15 Habilitación de todos los casos de uso	56
1.10 Habilitar el intercambio de datos.....	58
1.10.1 Resolviendo los desafíos técnicos.....	60
1.10.2 Lograr el éxito en el intercambio de datos	62
1.10.3 Monetizar los datos	63
1.11 Maximizar las opciones con una estrategia de nube múltiple.....	65
1.11.1 Particularidades de la nube múltiple	66
1.11.2 Aprovechamiento de la replicación global	67
1.11.3 Minimizar la interrupción del servicio.....	68
1.11.4 Gestionando nubes cruzadas.....	68
1.11.5 Protección de los datos	69
1.11.6 Simplificando la seguridad	69
1.12. Seguridad	71
1.12.1 Cifrado de datos por defecto	72
1.12.2 Aplicando el control de acceso.....	73
1.12.3 Parches, actualizaciones y vigilancia.....	74
1.12.4 Asegurar la protección, retención y redundancia de los datos ..	75
1.12.5 Requiere el aislamiento de los tenants.....	75
1.12.6 Mantener la gobernanza y el cumplimiento.....	75
1.12.7 Exigir certificados y certificaciones	76
1.13 Minimizando los costes de un almacén de datos	79
1.13.1 Minimizar el coste de almacenamiento.....	80
1.13.2 Maximizar la eficiencia de la computación	80
1.14 Consejos prácticos para empezar un data warehouse en la nube...	81

1.14.1 Paso 1: Evaluar las necesidades	82
1.14.2 Paso 2: Migrar o empezar de cero.....	83
1.14.3 Paso 3: Establecer los criterios de éxito	84
1.14.4 Paso 4: Evaluar las soluciones.....	85
1.14.5 Paso 5: Calcular el TCO.....	86
1.14.6 Paso 6: Establecer una prueba de concepto (POC o proof of concept).....	87
2. VENTAJAS Y DESVENTAJAS	90
2.1 Almacenamiento de datos en la nube frente al almacenamiento local	91
2.1.1 Evaluando el coste del tiempo.....	91
2.1.2 Los costes del almacenamiento y de computación	92
2.1.3 Dimensionamiento, equilibrio y tuning.....	93
2.1.4 Considerando los costes de preparación de datos y de ETL	93
2.1.5 Añadir el coste de las herramientas analíticas especializadas	96
2.1.6 Hacer concesiones para la escalabilidad y la elasticidad.....	96
2.1.7 Disminuyendo los retrasos y el tiempo de inactividad	98
2.1.8 Considerando los costes de los aspectos de seguridad	99
2.1.9 Pagar por la protección y recuperación de datos	99
RESUMEN	102

RESUMEN INTRODUCTORIO

A lo largo de esta unidad, se va a realizar una presentación de los conceptos básicos y de los fundamentos de la data warehousing.

Comenzaremos con los orígenes del concepto y la función que con ello perseguían sus creadores. Identificaremos cuales eran las limitaciones previas a la existencia del DWH que las compañías presentaban en la gestión y explotación de su información.

Tras ello, recorreremos la evolución histórica y los cambios tecnológicos que nos han traído al momento presente de los almacenes de datos. Estamos hablando de cuestiones como la reducción del coste del almacenamiento de datos, el incremento de la velocidad de los soportes de memoria no volátil, la irrupción del big data o la generalización del uso de la computación en la nube.

Entenderemos tanto las particularidades y complejidades que presenta una arquitectura de data warehouse, como los tipos de esquema más frecuentes para almacenar la información: estrella, copo de nieve o galaxia.

Posteriormente, pasaremos a presentar una metodología exhaustiva para realizar la elección de data warehouse que mejor se adapte a las necesidades del proyecto en el cual estamos involucrados.

Esta metodología presentada será válida para comparar cualquier escenario de data warehouse.

También será importante que el DWH satisfaga las nuevas tendencias en cuanto a información no estructurada y que, por tanto, permita convivir con eficiencia y productividad tanto al modelo relacional, como al modelo NoSQL.

Asimismo, la metodología es muy exigente con los temas de ciberseguridad, por dos motivos principalmente. El primero, la exigencia al respecto de las leyes y el riesgo potencial de las sanciones. El segundo motivo, proteger la información sensible albergada en los DWH, porque en muchas ocasiones es información confidencial y que podría poner en riesgo a la empresa si cae en manos no adecuadas.

Del mismo modo, la metodología entra en cuestiones financieras, dado que, como cualquier otro proyecto de sistemas de información, será necesario hacer una valoración objetiva del retorno de la inversión (ROI).

INTRODUCCIÓN

El data warehouse lleva siendo la piedra angular dentro de los sistemas de información corporativos que aporta capacidades de análisis avanzado.

Desde que Inmon y Kimball comenzaron hace tres décadas a definir los conceptos y modelos iniciales de los procesos de data warehousing, ya las empresas no han podido vivir ajenas a ello.

Probablemente, junto con internet, el data warehouse ha sido la tecnología que más millones de euros y dólares ha consumido en inversiones a todo tipo de compañías privadas, pero también a organizaciones públicas.

En la actualidad, el data warehouse no ha perdido un ápice de importancia. Más bien, por lo contrario, se puede decir que está viviendo una segunda época de esplendor, fundamentalmente por dos motivos.

El primero de ellos, sería el rejuvenecimiento que la nube le ha generado, porque el data warehouse se ha aligerado, ha ganado flexibilidad y, por tanto, ha soltado el lastre que siempre le ha perjudicado. El segundo de los motivos es que, nunca tanto como hoy, las empresas han valorado las capacidades de análisis y, nunca tanto como hoy, las empresas han dispuesto de tecnologías tan avanzadas para realizar inteligencia de negocio.

Sin duda, comprender los fundamentos de data warehouse e, incluso, especializarse en ello, es una oportunidad profesional de primer nivel. Además, hay que ser conscientes que, en este segmento de la informática, los perfiles profesionales son muy variados, por lo que es sencillo encontrar la posición o el rol que más se acomode a los gustos, preferencias y conocimientos de cada uno. Estamos hablando de puestos como administrador de base de datos, arquitecto de sistemas, expertos en ciberseguridad, analistas, ingenieros de datos, asesores de negocio, abogados expertos en datos, etc.

Igual de importante que es el data warehouse, lo es implementarlo de forma adecuada. Un enfoque de data warehouse incorrecto, probablemente limite y genere más problema que beneficios. Por este motivo, se ha introducido una guía metodológica en esta unidad que sirva de orientación para cualquier proceso de toma de decisión al respecto.

CASO INTRODUCTORIO

Una conocida cadena de supermercados e hipermercados está comprobando en los últimos tiempos como su cuota de mercado está bajando de forma preocupante. Intuyen que son varios los motivos.

Por un lado, la competencia agresiva en precios que realizan las denominadas cadenas de descuento. Por otro lado, también hay certeza de que la competencia online está llevándose a muchos de los clientes, por la comodidad que aporta. Se teme que, si la competencia y grandes empresas de venta online amplían su negocio de supermercados a toda España, sea imposible ya remontar la situación.

De igual modo, una tercera línea de competidores serían las cadenas de supermercados internacionales, que están creciendo muy rápido en España, con nuevos aires y productos atractivos a un precio competitivo.

Por parte de los responsables de marketing, también se tiene la sensación de que el cliente ha cambiado y que es mucho más difícil comprender sus gustos y tendencias.

El director financiero ha lanzado también una señal de alarma, en el sentido de que los proveedores están negándose a aceptar periodos de cobro tan dilatados como era costumbre y prefieren vender a otros clientes que pagan antes. Esto puede llegar a ahogar financieramente a nuestra compañía.

El mismo director financiero reseña que estas malas relaciones con los proveedores ya están afectando en algún caso a la logística y a la calidad, y determinadas entregas están llegando tarde o en malas condiciones a los puntos de venta.

Por este motivo, se ha pedido al departamento de sistemas de información que elabore una propuesta detallada de cómo enfocar la creación de un data warehouse corporativo, que permita mejorar las capacidades de análisis disponibles para hacer frente a los competidores y comprender mejor a los clientes, al tiempo que se optimizan los aspectos logísticos y financieros.

Tienes que hacer un análisis y valoración de los aspectos de negocio de tu compañía, para determinar qué características serán priorizadas en el data warehouse, así como cualquier otro condicionante que puedas identificar.

Al final de esta unidad habrás aprendido:

- El origen y evolución del concepto de data warehouse
- La utilidad y aplicabilidad de este
- Cómo elegir un DWH adecuado

1. CONCEPTO

En el caso de tu empresa, el interés de un data warehouse está muy claro. Junto con la banca y el denominado retail, ha sido de los sectores que antes comenzaron a utilizar DWH. Lo extraño es que la puesta en marcha se haya demorado tanto.

Parece claro que la decisión para lanzar un proyecto de data warehouse ha sido de forma reactiva, frente a un conjunto de problemáticas que se han acumulado y que ahora amenazan la supervivencia de la empresa. Por este motivo, el factor tiempo es especialmente importante.

Esto te lleva a pensar, como responsable de proyecto que, desde un punto de vista de metodología de proyectos, sería conveniente aplicar algún enfoque agile con lo que además se conseguirá que los usuarios del DWH lo puedan validar de forma recurrente y obtengan resultados desde los primeros momentos.

Dada la situación crítica por la cual pasa la empresa y que cualquier paso mal dado puede ser el anticipo de un final no deseado, has pensado que tienes que ser muy cuidadoso a la hora de identificar los criterios que vas a utilizar para seleccionar tu proveedor de nube y, especialmente, la solución de data warehouse.

Aunque estás recibiendo grandes presiones, porque todo el mundo está muy nervioso, tienes que auto convencerte de que debes retrasar unos pocos días el inicio del proyecto para que puedas realizar una buena identificación de criterios y en base a ello, elegir el proveedor más adecuado.

El data warehouse surgió para responder a problemáticas idénticas a las que la cadena de supermercados donde trabajas está padeciendo en este momento. En el caso del sector de la distribución comercial, un DWH puede ayudar a reducir mucho el tiempo consumido y los plazos de la toma de decisiones. Una cadena de supermercados es de las empresas que más proveedores tiene que gestionar.

El data warehouse es un término muy usado en la actualidad y muchas veces podemos cometer el error de pensar que es concepto muy específico, pero la realidad es que un data warehouse está formado por muchas partes que vamos a tratar de relatar en las siguientes páginas.

También es importante saber qué cualidades debe tener una buena data warehouse y saber que no es un data warehouse. Estudiaremos un poco sobre sus orígenes y su historia, así como algunos ejemplos que nos serán de utilidad para aprender sobre este fascinante mundo.

Lo primero que debemos entender sobre el data warehouse es que está compuesto por varios elementos que conforman un sistema integrado, el cual tiene como propósito explotar la información.

En los años 70, el científico de la computación Bill Inmon, comenzó a dar forma al concepto de data warehouse y publicó un libro llamado Building the Data Warehouse (construyendo el almacén de datos), que se convirtió en un gran éxito entre todas las publicaciones de tecnología en el año 1992.

En los años 90, el despegue definitivo de este concepto se produce en gran medida por la entrada en escena de otro científico de la computación, de nombre Ralph Kimball. Se trataba de un experto en el área y también autor de un conocido libro titulado The Data Warehouse Toolkit, aunque con una visión y tácticas alrededor del data warehouse ligeramente distintas a las de Inmon.

El concepto que nos propone Bill Inmon sobre el data warehouse es el de una colección de datos, no volátil, variante en el tiempo, integrada y orientada a algún asunto útil para la mejora de la toma de decisiones.

Los términos mencionados se explican del siguiente modo:

- **No volátil:** esto quiere decir que la información no se borra ni se reemplaza, solo crece por lo que es de naturaleza histórica.
- **Variante en el tiempo:** esto nos indica que la información cubre un periodo de tiempo específico.
- **Integrada:** Los data warehouse integran distintos sistemas para generar una vista panorámica sobre los datos de una empresa u organización.



SABÍAS QUE...

Bill Inmon tiene 75 años, es un informático estadounidense y está considerado el padre de data warehouse. Inmon escribió el primer libro, celebró la primera conferencia, escribió la primera columna en una revista y fue el primero en ofrecer clases de esta materia.

1.1 Definición de data warehouse


Las nuevas tecnologías como la nube han modificado el almacenamiento de datos, donde podemos decir que han separado un pasado del presente. Por ello, es interesante comprender los beneficios de utilizar la nube también a la hora de implementar un almacén de datos y comprender dónde encaja el almacenamiento de datos en la nube en el mercado actual.

Probablemente, la empresa tecnológica que más ha revolucionado la visión de los data warehouse en su evolución a la nube ha sido Snowflake. Esta empresa edita y actualiza periódicamente una guía con las mejores prácticas para evolucionar un almacén de datos hacia la nube.

En base a los preceptos propugnados en esta guía, vamos a identificar en los próximos apartados los aspectos clave para tener en cuenta para abordar con las mejores condiciones posibles la construcción de un DHW as a service.

De una forma u otra, la computación en nube y el software como servicio (SaaS) han existido desde hace décadas. Pero el almacenamiento de datos en la nube como servicio (DWaaS) ha surgido recientemente como una alternativa al almacenamiento de datos convencional en las propias instalaciones tanto de los clientes como de los proveedores. Varios han sido los motivos que han habilitado este cambio.

Comenzaremos definiendo qué es un almacén de datos y exploramos la evolución del almacenamiento de datos para mostrar cómo esta tecnología llegó a la nube. Posteriormente, analizaremos cómo las organizaciones pueden beneficiarse en la nube del DWaaS (Data Warehouse as a Service) y, explicaremos, por qué más compañías se apoyan en el almacenamiento de datos en la nube para competir en la economía actual impulsada por los datos.




RECUERDA

Un almacén de datos es un sistema informático dedicado a almacenar y analizar datos para revelar las tendencias, patrones y correlaciones que proporcionan información y conocimiento.

Tradicionalmente, las organizaciones han utilizado los almacenes de datos para almacenar e integrar los datos recogidos de sus fuentes internas

(normalmente bases de datos transaccionales), incluidas las relativas a marketing, ventas, producción y finanzas. El almacén de datos surgió cuando las empresas se dieron cuenta de que el análisis de los datos realizado directamente sobre esas bases de datos transaccionales las ralentizaba (e incluso las colapsaba), al estar sometidas a la presión de su actividad transaccional normal y las cargas de trabajo necesarias para analizar esos datos. Por lo tanto, la solución pasaba porque todos esos datos se duplicasen en un almacén de datos para su análisis, dejando que la base de datos original se centrara en las transacciones.

A lo largo de los años, las fuentes de datos se ampliaron más allá de las operaciones comerciales internas y las transacciones externas. En la actualidad presentan un volumen, una variedad y una velocidad de datos mucho mayores debido a la información que nace en los sitios web, los teléfonos móviles, las aplicaciones, los juegos en línea, las aplicaciones bancarias online e incluso las máquinas. Más recientemente, las organizaciones están captando enormes cantidades de datos desde los dispositivos de la internet de las cosas o IoT (Internet of Things).



VIDEO DE INTERÉS


En el siguiente vídeo se explica qué es IoT, los elementos que la componen y los requisitos para que funcione.

<https://www.youtube.com/watch?v=uY-6PcO96Bw&t=9s>

1.2 Evolución de data warehouse

Históricamente, las empresas reunían datos en formatos bien definidos y altamente estructurados a un ritmo y volumen razonablemente previsibles. Incluso a medida que se incrementaba la velocidad de las tecnologías más antiguas, el acceso a los datos y su utilización se controlaban cuidadosamente y se limitaban para garantizar un rendimiento aceptable para todos los usuarios, debido a la escasez de potencia de computación y almacenamiento en las instalaciones y a la dificultad de aumentar esos recursos. Esto requería que las organizaciones soportasen ciclos de análisis muy largos.

Todo esto ha cambiado, ya que los avances en la tecnología implican que las organizaciones pueden tomar decisiones comerciales importantes respaldadas por grandes cantidades de datos.



Surgimiento de data warehouse.

Fuente: elaboración propia a partir de Cloud Data Warehousing de Joe Kraynak y David Baum

Esto no ha sido así sólo en los líderes del mercado o las empresas más poderosas. Los pequeños y ágiles nuevos competidores están también transformando los negocios mediante la aplicación del análisis. Lo hacen con datos para descubrir oportunidades y desarrollar productos y servicios que cambien la forma en que las empresas se relacionan con sus clientes.



PARA SABER MÁS

Los almacenes de datos convencionales no fueron diseñados para manejar el volumen, la variedad y la velocidad de los datos de hoy en día. Los sistemas más recientes diseñados para abordar estas deficiencias pretenden adecuar el acceso a los datos y el análisis a lo que las organizaciones requieren ahora. Los desafíos de hoy en día muestran que:


- Las fuentes de datos son más numerosas y variadas, lo que da lugar a estructuras de datos más diversas que deben coexistir en un solo lugar para permitir un análisis exhaustivo y asequible.
- Las arquitecturas tradicionales provocan roces entre los usuarios y las actividades de integración de datos, lo que dificulta la carga simultánea de nuevos datos en el almacén de datos y la obtención de un rendimiento adecuado.
- La carga de datos en lotes a intervalos específicos (batch) sigue siendo común, pero muchas organizaciones requieren una carga continua de datos (microbatching) y datos en flujo (carga instantánea o stream).
- La ampliación de un almacén de datos convencional para satisfacer las crecientes demandas de almacenamiento y carga de trabajo de hoy en día, cuando es posible, resulta caro, difícil y lento.
- Las plataformas de datos alternativas más recientes suelen ser complejas y requieren conocimientos especializados y mucha puesta a punto y configuración. Esto se agrava con el creciente número y diversidad de fuentes de datos, usuarios y consultas.

La tecnología y la arquitectura de almacenamiento de datos (el diseño y los bloques de construcción del moderno almacén de datos) han evolucionado para hacer frente a las demandas de la economía basada en los datos con las siguientes innovaciones:

- **La nube:** Un factor clave que impulsa la evolución del moderno almacén de datos es la nube. La nube ofrece acceso a un almacenamiento casi infinito y de bajo costo, una mejor escalabilidad, la subcontratación de la gestión y la seguridad del almacén de datos al proveedor de la nube y la posibilidad de pagar sólo por el almacenamiento y los recursos informáticos realmente utilizados.
- **Procesamiento paralelo masivo:** que implica la división de una sola operación de computación para ejecutarla simultáneamente a través de un gran número de procesos informáticos separados. Esta técnica surgió a principios de la década de 2000. Es una división del trabajo

que facilita un almacenamiento y análisis más rápido de los datos cuando el software se construye adecuadamente para capitalizar este enfoque.

- **Almacenamiento columnar:** Tradicionalmente, las bases de datos almacenaban los registros en filas, de manera similar a como se hace en una hoja de cálculo. Por ejemplo, se podría incluir toda la información sobre un cliente o una transacción de venta. La recuperación de datos de la forma tradicional requería que el sistema leyera toda la fila para obtener un elemento. Esto es laborioso y lleva mucho tiempo. Con el almacenamiento en columnas, cada elemento de datos de un registro se almacena en una columna. Gracias a este enfoque, un usuario puede consultar un solo elemento de datos, por ejemplo, que suscriptores de un canal de televisión de pago han abonado sus cuotas mensuales, sin tener que leer todo lo demás en cada registro, como podría ser el número de identificación de cada miembro, el nombre, la edad, la dirección, la ciudad, el estado, la información de pago, etc. Este enfoque puede proporcionar una respuesta mucho más rápida a este tipo de consultas analíticas.
- **Procesamiento vectorial:** Esta forma de procesamiento para el análisis y ciencia de datos aprovecha los recientes y revolucionarios diseños de los procesadores de ordenador. Este enfoque ofrece un rendimiento más rápido frente a las antiguas soluciones de almacenamiento de datos construidas hace décadas pensadas para una tecnología de hardware más antigua y lenta.
- **Unidades de estado sólido (SSD):** A diferencia de las unidades de disco duro (HDD), las SSD flash, lo que acelera el almacenamiento, la recuperación y el análisis de los mismos. Una solución que aproveche las SSD suele ofrecer un rendimiento significativamente mejor.



Evolución de las ventas de unidades de disco SSD y HDD.


Fuente: <https://www.profesionalreview.com>

El **almacenamiento de datos en la nube** es una forma rentable para que las empresas aprovechen las últimas tecnologías y arquitecturas sin el enorme coste inicial de comprar, instalar y configurar el hardware, el software y la infraestructura necesarios. Las diversas opciones de almacenamiento de datos en la nube se agrupan generalmente en tres categorías:

- **Software tradicional de almacenamiento de datos desplegado en la infraestructura de la nube:** Esta opción es similar a la convencional, permitiendo reutilizar las instalaciones previas de data warehouse aprovechando gran parte código original. Este enfoque requiere contar con experiencia y conocimientos profundos en tecnologías de la información para construir y administrar el almacén de datos. Aunque bajo este modelo no es necesario adquirir e instalar el hardware y el software, es posible que se tenga que hacer una configuración y un ajuste significativos, así como realizar determinadas operaciones, como las copias de seguridad regulares.
- **Un almacén de datos tradicional alojado y gestionado en la nube por un tercero, en forma de servicio gestionado:** En este caso, el proveedor externo suministra la experiencia en tecnología de la información, pero es probable que la organización usuaria siga experimentando muchas de las limitaciones de un almacén de datos convencional. El almacén de datos está alojado en un hardware instalado en un centro de datos gestionado por el proveedor. Esto es

similar a lo que la tradicionalmente se ha denominado proveedor de servicios de aplicaciones o ASP por sus iniciales en inglés. Los clientes todavía deben especificar por adelantado cuánto espacio en disco y recursos de computación (CPU y memoria) esperan utilizar, lo que resta flexibilidad al enfoque.

- **Un verdadero almacén de datos SaaS:** Con esta opción, a menudo conocida como DWaaS, el proveedor entrega una solución completa de almacén de datos en la nube, que incluye todo el hardware y el software, y prácticamente elimina todas las tareas relacionadas con establecer y gestionar el rendimiento, la gobernanza y la seguridad necesarios en un almacén de datos. Los clientes suelen pagar sólo por el almacenamiento y los recursos informáticos que utilizan, durante el tiempo que los usan. Esta opción también puede ampliarse y reducirse a petición del cliente añadiendo cantidades ilimitadas de potencia de computación dedicada a cada carga de trabajo, mientras que un número ilimitado de cargas de trabajo funcionan simultáneamente sin afectar el rendimiento.



RECUERDA

Cualquier organización que dependa de los datos para servir mejor a sus clientes, racionalizar sus operaciones y liderar el mercado se beneficiará de un almacén de datos en la nube. A diferencia de los data warehouse tradicionales, la nube implica que las empresas grandes y pequeñas pueden dimensionar su almacén de datos para satisfacer sus necesidades a la medida de su presupuesto y hacer crecer dinámicamente su sistema a medida que las cosas cambian de un día para otro.

Estas son algunas áreas donde el almacén de datos en la nube puede mejorar significativamente las operaciones de una empresa:

- **La experiencia del cliente:** La supervisión del comportamiento de los clientes en tiempo real puede ayudar a las organizaciones a adaptar los productos, servicios y ofertas especiales a las necesidades de cada uno de los consumidores individuales. Mediante el análisis del sentimiento de los clientes, las empresas entienden mejor a los consumidores analizando cantidades masivas de publicaciones en medios sociales, tweets y otras actividades en línea.

- **Garantía de calidad:** Las organizaciones también pueden utilizar el streaming datos para vigilar las señales de alerta temprana sobre problemas en el servicio de atención al cliente o deficiencias de los productos. Pueden actuar en minutos u horas, en lugar de días o semanas, lo que no era posible cuando la única fuente de datos eran los registros de llamadas del call center.
- **Eficiencia operativa:** La inteligencia operacional consiste en supervisar el negocio y analizar los acontecimientos para identificar dónde puede una organización reducir los costes, aumentar los márgenes, agilizar los procesos y responder a las fuerzas del mercado con mayor rapidez. Al liberarse una empresa de la carga que supone la administración de un almacén de datos, puede concentrarse en el análisis de los mismos.
- **Innovación:** En lugar de sólo comprobar los datos históricos para entender el pasado reciente de un negocio, las empresas pueden utilizar nuevas fuentes de datos y análisis de ellos (predicción, prescripción, aprendizaje automático) para detectar y capitalizar las tendencias, transformando así su industria antes de que un competidor desconocido o imprevisto lo haga primero.

Casi todos los datos de una empresa se almacenan en una multitud de bases de datos dispares. Las preguntas clave que hay que hacer es: ¿Cómo de accesibles son esos datos? ¿Cuánto costará extraer, almacenar y analizar todos ellos? ¿Qué pasará y que se perderá si no lo hacemos? Aquí es donde el almacenamiento de datos en la nube entra en juego al ofrecer respuestas más sencillas a esas preguntas.

1.3 Por qué surgió el data warehouse

Los cambios que se describen en las características de los data warehouse más modernos tienen por objetivo adaptarse a las crecientes demandas de acceso y análisis de datos de las empresas en la actualidad, ajustándose a la forma en que los datos son creados y utilizados hoy en día y persiguiendo afrontar los desafíos con tecnologías nuevas y mejoradas.

Gran parte de los cambios acaecidos surgen por la convergencia de tres tendencias principales:

- Los cambios en las fuentes de datos, el volumen y la variedad de los mismos.
- El aumento de la demanda de acceso y análisis de datos.

- Las mejoras tecnológicas que aumentaron significativamente la eficiencia del almacenamiento, el acceso y el análisis de los datos.

Es interesante analizar estas tendencias con mayor detalle para comprender mejor cómo un data warehouse puede aprovecharse de los beneficios de la nube para hacer frente a estos y otros retos.




ENLACE DE INTERÉS

En el siguiente enlace se explica la historia de la data warehouse:

https://iude.webs.ull.es/investigacion/publicaciones/pdf_docs_trabajo/SERIE%20ESTUDIOS%200144.pdf

1.3.1 Tendencias de los datos: Volumen, variedad y velocidad

Cuando hablamos de datos en la época actual, estamos hablando de petabytes. Un petabyte es igual a un millón de gigabytes. Eso equivale a unos 500 mil millones de páginas de texto estándar impreso o más de 50.000 películas de alta definición, cada una de ellas de aproximadamente dos horas de duración.



Unidades de almacenamiento.

Fuente: instintoprogramador.com

Los datos provienen en gran medida de las operaciones diarias de un negocio, de las personas que utilizan sitios web y de las aplicaciones de software que


cada uno de nosotros utilizamos en nuestros dispositivos móviles, así como de la actividad diaria de la infinidad de dispositivos digitales y mecánicos que personas, familias y empresas manejan a diario.

En esta sección nos centramos en los cambios en los datos y en el uso de los mismos, que ha dado lugar a la gran demanda de almacenamiento de datos en la nube.

En un pasado no muy lejano, las empresas generalmente manejaban datos que las personas introducían manualmente en los sistemas de información. También podía haber datos de fuentes externas, como clientes y socios. La cantidad de datos era relativamente pequeña y predecible y los datos se almacenaban, administraban y aseguraban en el centro de datos de la compañía.


Hoy en día, el mundo de los negocios está experimentando un tsunami de datos, con datos disponibles desde una gran variedad de fuentes ya conocidas por todos y otras fuentes demasiado numerosas y variadas para enumerarlas. El volumen y la variedad de estos datos pueden abrumar rápidamente a las capacidades de un almacén de datos convencional y a menudo provoca que el procesamiento y el análisis de los datos se congestione o incluso que el sistema se bloquee, debido a la sobrecarga de los usuarios y a las cargas de trabajo que se procesan en un momento dado.

La adaptación al aumento exponencial de los datos requiere una nueva perspectiva. La situación debe pasar de lo grande que debe ser el almacén de datos de una organización a si puede escalar de forma rentable, sin fricciones y en el orden de magnitud necesario para manejar volúmenes masivos de datos a corto, medio y largo plazo.



El moderno almacén de datos permite todos los datos para todos los usuarios.

Fuente: elaboración propia a partir de Cloud Data Warehousing de Joe Kraynak y David Baum

**RECUERDA**

Los casos de uso que el almacenamiento de datos en la nube ha definido no son estáticos, sino que siguen surgiendo nuevos escenarios de aplicación.

Por ejemplo, las empresas nacidas gracias a la creación de un SaaS y las grandes compañías que utilizan la nube para almacenar sus datos están monetizando (vendiendo) esos datos. Los empaquetan como un servicio y los venden a otras organizaciones interesadas en tomar decisiones comerciales aún mejores desde la perspectiva más precisa posible.

Las organizaciones han experimentado una rápida adopción del SaaS, especialmente en lo que tiene que ver con el software de gestión de relaciones con el cliente (CRM que son las iniciales de customer relationship management), suites de software de planificación de recursos empresariales (ERP que son las iniciales de Enterprise Resource Planning), plataformas de compra de publicidad y herramientas de marketing online, por nombrar sólo algunas. Gracias a la nube, las nuevas empresas de SaaS pueden nacer con una inversión muy baja.

Estos productos SaaS crean enormes cantidades de datos valiosos almacenados en la nube. Además, las organizaciones de gran tamaño que son proveedores de las empresas de SaaS como Amazon, Google o Microsoft, proporcionan una mejor seguridad de lo que le es posible a estas compañías, que muchas veces están todavía en una etapa de start up.

La demanda de aplicaciones SaaS en particular y cloud en general también ha crecido. La facilidad de despliegue que ofrecen ha arrasado a lo que las aplicaciones on premise requieren para ponerse en marcha. En el pasado, una empresa puede haber operado sólo entre cinco y diez aplicaciones empresariales importantes que generaban datos. Ahora, es normal que incluso las organizaciones medianas tengan cientos o incluso miles de aplicaciones, cada una con el potencial de crear su propio silo de datos, por ejemplo, datos de marketing en un sistema, finanzas en otro, información de productos en otro, etc y ninguna de ellas integrada para un análisis completo y óptimo.

Con la mayoría de los datos de una organización ahora en la nube, el lugar natural para integrar estos datos es también en la nube. Con el almacenamiento de datos en la nube, ya no es obligado que se encuentren dentro del centro de datos de la compañía, lo cual es costoso y consume

tiempo y tiene menos sentido a medida que la cantidad de datos nativos de la nube crece.



SABÍAS QUE...

Los datos generados por máquinas son un tema clave relacionado con el internet de las cosas (IoT), que básicamente se trata de una colección interminable de dispositivos que comunican datos a través de internet, incluyendo teléfonos inteligentes, termostatos, calderas, plataformas petrolíferas, sistemas de seguridad para el hogar, medidores inteligentes y mucho más. Los datos recogidos y analizados de los dispositivos de IoT pueden mejorar los productos y procesos, monitorizar un equipo y predecir el mantenimiento necesario para evitar fallos.

Pero muchos de los datos generados por máquinas tienen una pobre relación señal-ruido. Es decir, contienen datos valiosos, pero también mucho "ruido".

Por lo tanto, a menudo hay que almacenarlos todos inicialmente para, posteriormente, encontrar la información realmente valiosa. Además, una parte cada vez mayor de estos datos se origina fuera de los centros de datos corporativos. Esto hace que la nube y su escalabilidad casi infinita, sea el lugar natural para almacenar e integrar estos datos.

El análisis de los datos comienza con la exploración de los mismos, identificando conexiones interesantes y valiosas y sirviéndolas a los usuarios en forma de informes y análisis. Aunque la explotación de datos no es un concepto nuevo, el crecimiento del volumen de datos lo convierte en un ejercicio más intensivo en recursos que en el pasado.

La exploración de datos a menudo implica trabajar sobre grandes conjuntos de datos. También suele ser de naturaleza experimental, lo que complica la evaluación del retorno de la inversión, algo necesario si tenemos en cuenta lo importante que puede llegar a ser el coste inicial del despliegue de un almacén de datos tradicional on premise. Por lo contrario, la nube puede permitir que un almacén de datos se amplíe y reduzca según sea necesario y ofrece un modelo de pago por uso que permite a las organizaciones evitar la pregunta de si deben o no hacer un desembolso costoso por adelantado.

La creciente necesidad de tener cantidades masivas de datos en bruto en diferentes formatos, todos en un solo lugar, dio lugar a lo que ahora se denomina como data lake. Las organizaciones se dieron cuenta rápidamente

de que estas soluciones tenían un costo prohibitivo, ya que transformar esos datos y extraer conocimientos valiosos de ellos era casi imposible.



ARTÍCULO DE INTERÉS

En este artículo de James Dixon (en inglés) se utiliza por primera vez la expresión Data Lake.

<https://jamesdixon.wordpress.com/2010/10/14/>

Pero el interés original en los data lakes dejó claro que las empresas querían almacenar todos sus datos en un solo lugar a un coste razonable. Añadiendo un moderno almacén de datos en la nube al lago de datos existente o construyendo el lago de datos dentro del almacén de datos, se puede lograr fácilmente esa visión original para el data lake, consistente en cargar, transformar y analizar de forma rentable cantidades ilimitadas de datos estructurados y semi-estructurados, con recursos de almacenamiento y computación casi ilimitados.

1.3.2 Tendencias en materia de presentación de informes y análisis

La toma de decisiones basada en datos ya no está supeditada a los científicos de datos. Ahora se utiliza por múltiples usuarios para mejorar casi todos los aspectos operativos de una empresa. Pero esta creciente demanda de acceso a datos y análisis en toda la organización puede ralentizar o colapsar un sistema mientras las cargas de trabajo pelean por el almacenamiento y los recursos de computación de los almacenes de datos tradicionales. La eficiencia disminuye, lo que obliga a las empresas a invertir más tiempo y dinero en infraestructura adicional para mantener el sistema en unos parámetros razonables.

Por lo anteriormente descrito es interesante identificar algunas de las tendencias que cambian la forma en que las personas acceden y utilizan los datos y cómo esas tendencias impulsan la necesidad de soluciones de almacenamiento de datos modernas y construidas para la nube. Estas tendencias son:

- **Aprovechar la elasticidad para permitir el análisis**

La exploración de datos ofrece muchos beneficios. Pero nadie sabe de antemano los recursos de computación necesarios para analizar enormes conjuntos de datos, lo que hace que la escalabilidad elástica y bajo demanda sea ideal para este tipo de análisis.

El análisis de datos ad hoc, que se presenta constantemente en todo tipo de organizaciones, responde a una única y específica pregunta de negocios. La elasticidad dinámica y los recursos dedicados a cada carga de trabajo permiten estas consultas sin ralentizar otras cargas de trabajo en el mismo momento en que surgen.

Los análisis basados en eventos requieren datos constantes. Incorporan nuevos datos para actualizar los informes y los cuadros de mando de forma continua, para que los directivos puedan supervisar el negocio en tiempo real o casi real. La ingesta y el procesamiento del flujo de datos requiere un almacén de datos elástico para manejar las variaciones y los picos en el propio flujo de datos.

- **Sustituir la planificación previa exhaustiva por la iteración rápida**

Las empresas suelen tener dos caminos a seguir para asegurar el éxito comercial de una nueva idea: una planificación previa exhaustiva o una iteración rápida. La primera opción es un proceso tradicional que requiere mucho tiempo y que implica pensar en una oportunidad o en una nueva idea de producto, dar vueltas a las ideas y esperar a que se cree una demanda de consumo. La iteración rápida implica probar rápidamente la idea en el mercado para iterar una y otra vez hasta que una versión viable del producto tenga éxito. A partir de ahí, el proceso comienza de nuevo.

La iteración rápida ha surgido como el proceso más eficaz para atacar a competidores fuertemente establecidos y alterar la forma en que toda una industria hace negocios. Pero requiere la recolección y el análisis a alta velocidad de grandes cantidades de datos precisos para tener éxito. Los avances en el almacenamiento y análisis de datos en la nube han hecho que la iteración rápida sea más práctica, a la vez que se preserva la precisión de los datos.



SABÍAS QUE...

Jana es una empresa de telecomunicaciones, actualmente parte del grupo Oxigen, que proporciona acceso gratuito y sin restricciones a internet a millones de usuarios de teléfonos inteligentes en más de 15 mercados emergentes. Con su aplicación mCent para Android, Jana traslada el coste del internet móvil de los clientes a más de 4.000 marcas que lo subvencionan a cambio de introducir publicidad en forma de contenido patrocinado.

Cuando se introducen nuevos contenidos en mCent, Jana analiza y mide las métricas clave, incluyendo la atención del usuario, el valor de vida del usuario y los indicadores clave de rendimiento o key performance indicators (KPI).

A medida que Jana y sus datos crecían, la arquitectura analítica inicial de la compañía ya no podía servir eficientemente a su negocio. Las consultas se ralentizaron y muchos de los análisis que se realizaban se volvieron inviables. La agregación de nuevas capacidades y sistemas de respaldo, así como la administración del repositorio de datos de código abierto de Jana requería cada vez más tiempo de administración.

Como se ilustra en la figura, Jana actualizó la mayoría de los componentes de su plataforma de datos para racionalizar su sistema mediante un data warehouse construido en la nube para superar estas barreras y obtener los siguientes beneficios:

- Mantener el ritmo de respuesta a las peticiones comerciales de procesamiento y análisis sobre un flujo de datos dispares y en rápido crecimiento.
- Fomentar un mayor uso de la analítica en toda la empresa, dado que el 80% de los empleados de Jana accede al almacén de datos.
- Reducir significativamente los gastos de administración.



Enfoque de data warehouse de Jana

- **Integrar el análisis**

Para muchas empresas, la analítica funciona como un proceso de negocio separado y distinto. Pero la tendencia creciente es incorporar

el análisis en las aplicaciones de negocio de todo tipo, que cada vez más se construyen en la nube. Estas aplicaciones responden a un perfil muy heterogéneo y numeroso de usuarios que consultan las aplicaciones y el número de consultas (cargas de trabajo) que los usuarios ejecutan para analizar esos datos tienden a crecer.

La nube facilita la transferencia de datos de las aplicaciones basadas en la nube al almacén de datos también en la nube de la organización, donde su escalabilidad y elasticidad pueden soportar mejor las fluctuaciones de los usuarios y las cargas de trabajo.

1.3.3 Las nuevas tecnologías son imprescindibles para cualquier almacén de datos moderno

Las innovaciones tecnológicas pueden mejorar el almacenamiento de datos y la analítica en lo que respecta a la disponibilidad, la simplicidad, el coste y el rendimiento. Vamos a ver las tecnologías clave que deberían formar parte de cualquier almacén de datos moderno.

Nube

Las propiedades de la nube la hacen particularmente adecuada para el almacenamiento de datos. Hemos mencionado esto anteriormente, pero es importante recordar los aspectos clave que se originan con el uso de la nube:

- **Recursos ilimitados:** La infraestructura de la nube ofrece recursos casi ilimitados, bajo demanda, y actualizables en minutos o segundos. Las organizaciones pagan por segundo sólo por aquello que utilizan, lo que hace posible apoyar dinámicamente cualquier escalado de usuarios y cargas de trabajo sin comprometer el rendimiento.
- **Ahorra dinero, porque facilita concentrarse en los datos:** Las empresas que eligen una solución construida en la nube evitan la costosa inversión inicial de hardware, software y otras infraestructuras, así como los costes de mantenimiento, actualización y seguridad de un sistema on premise. Por lo contrario, todos los recursos se centran en el análisis de los datos.
- **Punto de integración natural:** Según algunas estimaciones, hasta el 80% de los datos que se quiere analizar provienen de aplicaciones fuera del centro de datos de la empresa. Reunir esos datos en la nube es más fácil y barato que construir un centro de datos interno porque no se tiene que invertir millones de euros en hardware y software por adelantado y luego pagar al personal técnico para mantener esos recursos.

Almacenamiento en columna: procesamiento

Como ya se ha mencionado, el almacenamiento en columnas mejora considerablemente la eficiencia y el rendimiento del almacenamiento, la recuperación y el análisis de los datos, lo que permite a los usuarios del sistema un acceso más rápido a los resultados.

Unidades de estado sólido (SSD)

A diferencia de las unidades de disco duro (HDD), las SSD almacenan datos en chips de memoria flash, que aceleran el almacenamiento, la recuperación y el análisis de los datos. Estas mejoras aumentan la potencia de cálculo de los almacenes de datos diseñados para aprovechar las unidades SSD de forma eficaz.

NoSQL

NoSQL, abreviatura de no sólo SQL, que es un enfoque de base de datos alternativo al SQL y que ya hemos estudiado con profusión en este curso, describe una tecnología que permite el almacenamiento y análisis de nuevas formas de datos, como los datos generados por máquinas y por medios sociales, para enriquecer y ampliar los datos analíticos de una organización. Los almacenes de datos tradicionales no se adaptan muy bien a estos tipos de datos. Por lo tanto, en los últimos años han surgido nuevos enfoques, como JSON, Avro y XML, para manejar estas formas de datos semiestructurados.



PARA SABER MÁS

Apache Avro™ es un sistema para serializar datos en un formato binario compacto. Una estructura de datos Avro se define en un esquema Avro, que está escrito en formato JSON. A la hora de la implementación, un documento Avro se suele serializar como archivo binario que contiene no sólo las estructuras de datos Avro, sino también el esquema Avro que se usó para definir dichas estructuras.

En su página web oficial puedes encontrar más información:

<https://avro.apache.org>


Algunos de estos sistemas NoSQL fueron diseñados con la intención de reemplazar los almacenes de datos tradicionales, pero terminaron complementándolos mayormente. Para obtener valor de los datos

semiestructurados, las organizaciones a menudo tienen que extraer y transformar los datos de un sistema NoSQL y cargarlos en un almacén de datos tradicional para que los usuarios de negocio puedan acceder a ellos fácilmente. Como resultado, esto añade otra capa de complejidad y coste para las empresas, como por ejemplo le ocurría a Jana en el ejemplo descrito anteriormente, al intentar aprovechar los beneficios de ambos tipos de sistemas.

Por consiguiente, un almacén de datos moderno construido en la nube debe incorporar y optimizar la ingesta y la consulta de formatos de datos estructurados (tradicionales) y semiestructurados, para que las organizaciones no se vean obligadas a invertir y gestionar dos sistemas en paralelo.

1.4 Arquitectura de un data warehouse

El data warehouse forma parte de un todo, como podemos observar en el gráfico y existen varias capas que pueden interactuar con él.



Arquitectura genérica de un data warehouse

La manera de interactuar más frecuente en el entorno de un data warehouse es el proceso ETL (extract, transform y load) o extracción, transformación y carga.

El data warehouse está conformado por tres elementos fundamentales:

- **El load manager:** Este será el encargado de la carga de los datos provenientes de otras fuentes tales como ERPs, sistemas, aplicaciones, etc. También tiene como misión la conversión de estos datos en información utilizable y dentro de sus principales tareas están:
 - Identificación de datos.
 - Validación de la exactitud de los datos.
 - Extracción de datos de la fuente original.
 - Limpieza de los datos.
 - Formateado de los datos.
 - Estandarización de los datos.
 - Consolidación de múltiples fuentes de datos.
 - Establecimiento de la integridad de los datos utilizando constantes de integridad.
- **Warehouse manager:** Es la parte de data warehouse que se encarga de gestionar la enorme cantidad de datos. Organiza los datos de manera que resulte sencillo realizar análisis sobre los mismos y es el núcleo de data warehouse, que mantiene distintos niveles de información y de metadatos.
- **Data access manager:** Este es el encargado de conectar los datos con el usuario final, haciendo uso de herramientas especializadas, por ejemplo, herramientas de data mining. Existen de varios tipos, por ejemplo, de consulta y recuperación de información, estadísticas, descubrimiento de datos, etc.

1.5 Importancia de data warehouse

Entre los aspectos que hacen de data warehouse una pieza clave de la informática empresarial, podríamos destacar los siguientes:

- La integración de los datos, desde distintas fuentes, es de fundamental importancia para poder realizar estudios sobre los mismos.
- Permite el almacenamiento de datos de manera ordenada y siguiendo un criterio.
- Salvaguardar los datos es de vital importancia.
- Tener los datos en un formato estandarizado es clave a la hora de hacer estudios de manera rápida y acertada.
- Aportan una alta tasa de ROI (retorno de la inversión). Según algunos estudios puede llegar a ser de hasta un 400% de retorno. Esto es importante, ya que el data warehouse representa una gran inversión.

- Las ventajas a nivel competitivo son altas, porque conocer los hechos antes de que sea demasiado tarde, aporta una ventaja enorme a las empresas y organizaciones.



EJEMPLO PRÁCTICO

Una compañía dedicada a la producción de cereales ha decidido iniciar un proceso para desarrollar una agricultura inteligente. Por este motivo, ha instalado sensores que miden temperatura, humedad, nitratos en el suelo, etc. También cuenta con un CRM y como hacen trading y negocian en el mercado de futuros, cuentan con una plataforma financiera muy potente.

A pesar de todo este esfuerzo, tienen la sensación de que cuanta más información disponen, peor salen los resultados.
¿Cómo lo solucionarías?

Solución

Cuando se manejan datos de muchas fuentes, disponer de un data warehouse es fundamental para poder integrarlos y sacarle provecho a esa integración. Esta compañía necesita integrar su CRM, finanzas y sensores en una misma plataforma.

Además, en el caso de esta empresa que produce cereales, todo esto es más crítico por la interrelación en tiempo real entre todos los datos. Pensemos que, por ejemplo, si una medición del suelo indica que la cosecha de este año va a ser de peor calidad, eso puede influir inmediatamente en los precios que se negocian a través de la plataforma financiera de trading.

Seguro que una inversión en un DWH ofrece un ROI excepcional en este caso por lo que los responsables de la compañía no deberían albergar dudas.

1.6 Limitaciones de data warehouse

Por lo contrario, los data warehouse también tienen detractores y son varios los puntos débiles que se asocian a ellos. Entre los más mencionados se encuentran:

- **Errores en las fuentes de los datos:** esto va más allá del estudio de los datos. Si tenemos datos equivocados o capturados de manera incorrecta, el estudio arrojará resultados falsos.


- **Las demandas de los clientes:** si no se hacen proyecciones correctas, podemos quedarnos cortos, ya que los clientes están en constante cambio cuando de sus necesidades se trata.
- **El alto coste del hardware:** esto puede provocar que exista una limitación en los análisis, debido a las altas demandas de almacenamiento y proceso de datos.
- **Perdida de datos durante las fases de preprocesamiento de datos.**

1.7 Esquemas de data warehouse

Dentro de nuestro data warehouse debemos elegir de qué manera guardaremos la información. Para esto existen varios esquemas muy usados a lo largo de los últimos tiempos y otros más recientes.


Para entender los esquemas, debemos primero estudiar tres conceptos muy importantes:

- **Dimensión:** llamaremos dimensión a una colección de información sobre un evento que se puede medir. Estos eventos serán almacenados en una tabla de hechos. Los hechos son las entidades de la organización que se buscan almacenar, para luego ser estudiados. Por ejemplo, una dimensión sobre unos estudiantes podría ser los atributos nombre, dirección, edad, genero etc. Una tabla de dimensión estará compuesta por un id único y sus otros atributos.
- **Medida:** Es una propiedad con la que se puede realizar cálculos, promedios, mínimos, máximos.
- **Tabla de hechos:** La tabla de hechos no es más que un conjunto de datos asociados, y está compuesta por medidas y dimensiones.



Estructura de una tabla de hechos
Fuente: elaboración propia

Una **tabla de hechos** normalmente está compuesta por **claves foráneas** y medidas.




Como hemos visto, una tabla de hechos puede estar asociada a muchas dimensiones y estas dimensiones se pueden organizar de distintas maneras o esquemas.

1.7.1 Esquema de estrella

Este es el esquema más simple y debe su nombre por la forma que adopta, donde cada punta vendría a ser una dimensión y cada una de esas puntas debe ser de una sola dimensión.

Sus principales características son:

1. Tiene un muy buen rendimiento en las consultas ya que no hay necesidad de realizar joins.
2. Es una estructura simple de entender.
3. Su implementación suele demorarse un poco debido a la necesidad de la desnormalización.
4. Al ser el esquema más usado existen gran cantidad de herramientas para él.




Esquema de estrella.
Fuente: elaboración propia

Ventajas

- Las consultas son sencillas y no requieren operaciones de tipo join.
- La generación de informes es más sencilla.
- Las consultas son rápidas.

Desventajas


- Los procesos para la integridad de los datos son muy difíciles de aplicar, debido a la redundancia de los datos.
- Las inserciones de datos pueden generar anomalías debido a la redundancia de los datos.
- Son muy limitados los tipos de análisis que este esquema permite en comparación con otros más complejos y normalizados.

**RECUERDA**

Desnormalización es el proceso en el cual, para buscar la optimización, es necesario agregar cierto nivel de redundancia.

1.7.2 Esquema de copo de nieve (snowflake)

En este tipo de esquema las dimensiones estarán normalizadas y esa es su principal diferencia en comparación con el esquema de estrella. Las dimensiones se dividen para normalizar los datos, creando una estructura única similar a la de un copo de nieve.



Esquema copo de nieve.
Fuente: elaboración propia

Entre sus características están:

1. Nivel bajo de redundancia de datos.
2. Tiene una estructura compleja
3. Permite realizar estudios más complejos
4. Mayor integridad en los datos.

Ventajas

- Ahorra espacio de almacenamiento
- Muchas herramientas están optimizadas para el trabajo con este tipo de esquemas

Desventajas


- Gran complejidad en las consultas, debido a que los datos están normalizados.
- Su rendimiento suele ser bajo, debido a los joins que se deben realizar en sus consultas.

1.7.3 Esquema de galaxia

Este esquema tiene como principal diferencia que posee más de una tabla de hechos. Se puede decir que se trata de un conjunto de esquemas tipo estrella, aunque estos pueden compartir tablas en común.

Sus características son:

1. Posee múltiples tablas de hechos, por ende, los análisis pueden hacerse de manera más simple.
2. Es una mejora del modelo clásico de estrella.
3. Comparten dimensiones entre los distintos hechos.
4. Posee una estructura de datos normalizada.



Esquema galaxia.

Fuente: elaboración propia

Ventajas:

- Genera un gran valor al usuario final, ya que permite el estudio de múltiples hechos.
- Promueve la reutilización de datos, ya que las dimensiones se pueden compartir con las distintas tablas de hechos.

- Promueve la no redundancia de datos.

Desventajas:

- No es soportado por todas las herramientas de análisis.
- Al ser un esquema grande: genera gran complejidad a la hora de su implementación.

**ENLACE DE INTERÉS**


En el siguiente enlace puedes aprender más sobre los esquemas de data warehouse.

<https://datamanagement.es/2020/04/03/esquemas-data-warehousing/>

1.8 Criterios de selección de un data warehouse

A continuación, vamos a conocer los aspectos a tener en cuenta para realizar la elección de la solución más adecuada para el almacenamiento de datos, buscando un equilibrio óptimo entre rendimiento y coste, al tiempo que se hace de la seguridad, la protección y la gobernanza de los datos una prioridad.

Como ya hemos analizado, las tendencias de mercado llevan a la necesidad y a la oportunidad de crear un nuevo tipo de almacén de datos que esté diseñado y construido de forma adecuada para el volumen, la variedad y la velocidad de los datos de hoy en día y para las nuevas formas en que las organizaciones utilizan sus datos. Tal solución, también somos conscientes, debe aprovechar las innovaciones tecnológicas clave, especialmente todo lo que tiene que ver con la nube.

**RECUERDA**

Cuando nos vemos en la tesitura de tener que tomar decisiones sobre que enfoque utilizar y que tecnologías de data warehouse adquirir, disponer de una lista de criterios nos ayudará a determinar qué alternativa se ajusta mejor a las necesidades de nuestra organización.

En los siguientes apartados vamos a definir una lista de verificación o checklist que nos sirva para encontrar la mejor solución de data warehouse para la empresa en la que trabajamos o para los clientes a los cuales prestamos servicio.

1.8.1 Satisface las necesidades actuales y futuras

La verdadera elasticidad aporta beneficios económicos, pero puede ofrecer muchos más. Una buena arquitectura en la nube debería poder escalar tanto los recursos de computación como el almacenamiento de forma independiente, para no obligar a añadir más almacenamiento, cuando en realidad sólo se necesite más computación y viceversa. Esa es una característica clave de un almacén de datos elástico.

1.8.2 Almacena e integra todos los datos en un solo lugar

Los datos no tradicionales o semiestructurados, como se ha indicado anteriormente, pueden enriquecer la comprensión del análisis de los datos más allá de los límites tradicionales. Pero esto requiere un nuevo enfoque para cargar y transformar estos nuevos tipos de datos antes de que la organización pueda analizarlos. La mayoría de los almacenes de datos tradicionales sacrifican el rendimiento o la flexibilidad para manejar estos tipos de datos. Un almacén de datos moderno debería eliminar la necesidad de diseñar y modelar por adelantado estructuras rígidas, como convencionalmente se ha venido haciendo, que requerirían la transformación de datos semi-estructurados antes de cargarlos. También debería optimizar el rendimiento de las consultas contra estos tipos de datos mientras aún están en sus formas nativas. En general, el almacén de datos debería soportar datos diversos con flexibilidad, evitando al mismo tiempo problemas de rendimiento.

Cargar eficientemente todos los datos corporativos en un solo lugar es crucial. Pero integrar todos esos diversos tipos de datos para un análisis más preciso es otra cosa. Un almacén de datos moderno debería integrar automáticamente sus datos semi-estructurados, una vez albergados en repositorios NoSQL, con datos estructurados inherentes a una base de datos relacional. No debería haber que instalar ni configurar nada especial y la puesta a punto y el tuning deberían ser muy sencillos. Y lo que es más importante, las empresas no deberían confiar en arquitecturas que les obliguen a mantener y pagar por dos sistemas separados para manejar todos sus datos.

1.8.3 Apoya las habilidades, herramientas y conocimientos existentes

Los almacenes de datos tradicionales están obsoletos en gran medida porque la tecnología de base que los sustenta ya tiene cuatro décadas de historia por lo que no es fácil rediseñarla para la nube. Esta larga historia también implica que el lenguaje en el que se basan, el SQL, sigue siendo un pilar de la industria. Debido a esto, existe una amplia gama de herramientas tanto maduras, como emergentes, de gestión de datos, transformación de datos, integración, visualización, inteligencia de negocios y análisis que se comunican con un almacén de datos SQL. La funcionalidad ampliamente divulgada del SQL estándar implica que un gran número de personas, no solo informático, tienen conocimientos de SQL.



SABÍAS QUE...

negocio.

Chime es un banco online pensado para usuarios jóvenes que se han denominado la generación móvil. Chime recopila y analiza datos a través de plataformas móviles, web y de servidores back-end para mejorar la experiencia de usuario de sus clientes y, al mismo tiempo, aportar valor a su

Analizar las métricas clave de los negocios en Chime fue laborioso e implicó reunir y analizar datos de un gran número de servicios, incluyendo los servicios de anuncios de Facebook y Google. Chime también obtuvo datos de los eventos de otras herramientas analíticas de terceros, la mayoría de las cuales proporcionaban datos semi-estructurados en formatos como JSON.

Chime satisfizo los siguientes requisitos con su almacén de datos en la nube:

- Entregar eficientemente datos estructurados y semiestructurados y ponerlos a disposición para su consulta casi en tiempo real, utilizando tablas estándar de bases de datos SQL.
- Simplificar su pipeline de datos sin necesidad de diseñar un nuevo modelo para cada nuevo tipo de datos cargado en el data warehouse.
- Escala arriba y abajo para satisfacer las demandas de la carga de trabajo y controlar los costes de forma que ni faltasen ni sobrasen recursos en cada momento.
- Integrarse rápidamente y sin complicaciones con herramientas de análisis de datos de terceros.
- Habilitar SQL en lugar de otras opciones que requieren complicados lenguajes de programación para extraer y analizar datos de forma que los consultores y analistas del banco pudiesen utilizar desde el primer momento el sistema sin tener que aprender nuevos lenguajes de consulta o de análisis.

Los analistas de Chime con este enfoque de data warehouse modelan más escenarios para mejorar los servicios de los usuarios y clientes, pasan menos tiempo esperando los resultados de las consultas mientras que pasan más tiempo analizando los datos que es lo que realmente aporta valor a la compañía.

Los almacenes de datos tradicionales soportan SQL, pero no tienen las capacidades necesarias para almacenar y procesar eficazmente datos semiestructurados. Por ello, muchas organizaciones han recurrido a enfoques alternativos, como las soluciones NoSQL. Las limitaciones de estos sistemas plantean otro problema. Requieren conocimientos y aptitudes especializados que no están ampliamente disponibles y podrían no ser compatibles con SQL. Un almacén de datos moderno debe estar diseñado con tecnología de punta, pero construido sobre estándares inclusivos y de uso generalizado (como SQL), debiendo ser compatible con otras habilidades y herramientas comúnmente disponibles en la industria, como los lenguajes de computación Spark, Python y R de uso frecuente entra analistas, científicos de datos, ingenieros de datos, analistas de producto, etc.

1.8.4 Ahorrar dinero a la organización

Un almacén de datos convencional puede costar millones de euros en pagos por uso de licencias de software, compra de hardware y contratación de servicios de apoyo como consultoría y formación. Además, si tenemos en cuenta el tiempo y la experiencia necesarios para establecer, administrar, desplegar y ajustar el almacén, así como los costes para asegurar y respaldar los datos, la factura de un data warehouse puede elevarse a importes económicos muy importantes.

Además, la construcción de un almacén de datos que cumpla los requisitos de negocio y aproveche plenamente el volumen y la variedad de los datos actuales, suele tener un coste todavía más prohibitivo para cualquier organización.

Un moderno almacén de datos debería afrontar estos retos a un precio mucho más bajo. Por ejemplo, ¿escalan el almacenamiento y la distribución de resultados por separado para que no sea necesario pagar por recursos que no se necesitan? ¿También escalan adecuadamente las cargas de trabajo y la concurrencia? ¿Soportará diversas estructuras de datos e integrará diversos datos en un solo lugar? ¿Experimenta un tiempo de inactividad mínimo o nulo y ofrece la opción de entregar actualizaciones automáticamente o por etapas? Y finalmente, ¿puede hacer todo esto automáticamente sin la complejidad, el gasto y las complicaciones típicas de ajustar manualmente el sistema para obtener el mejor rendimiento?

Con el almacenamiento de datos en la nube, la tarifa de servicio pagada al proveedor debería cubrir todo ello por una pequeña fracción del coste de una solución convencional on premise. Pero no todas las soluciones basadas en la nube son iguales. Las diferencias entre ellas también determinan cuánto debe pagar un cliente, de una forma u otra, para obtener una valiosa explotación de la información y el conocimiento albergado en sus datos.

1.8.5 Proporciona resistencia, tolerancia y recuperación de datos

Muchos tipos de fallos en los data warehouse pueden causar pérdida de datos o incongruencias. Por lo tanto, un almacén de datos debe mantener sus datos seguros, actualizados y disponibles. Los almacenes de datos tradicionales protegen los datos de manera típica realizando copias de seguridad periódicas, que consumen valiosos recursos de computación e interfieren con las cargas de trabajo continuas. Las copias de seguridad periódicas también requieren un almacenamiento adicional y a menudo no incluyen los datos más recientes, lo que provoca inconsistencias en ellos.

Un almacén de datos moderno debería administrarse a sí mismo cuando se trata de asegurar la durabilidad, resistencia y disponibilidad del sistema. No debería interferir con ninguna carga de trabajo en curso, ni degradarse, ni acabar en una falta de disponibilidad del servicio debido a los procesos de copia de seguridad que se ejecutan en segundo plano. Además de todo ello, debería ser barato, con mecanismos inteligentes para preservar sus datos sin tener que copiar y moverlos a otro lugar. Finalmente, debería tener una arquitectura multi-nube que le de portabilidad para reubicar los datos y las cargas de trabajo a medida que el negocio se expande, tanto entre regiones geográficas como entre los principales proveedores de nubes, como Amazon, Microsoft y Google.

Recordemos que estos proveedores de nube están en constante crecimiento por lo que no sabemos si en el futuro nos resultará más interesante cambiar de proveedor.

Recordemos igualmente que cada proveedor de nube abre de forma periódica nuevos centros de procesamiento de datos, lo que hace que debamos mover nuestros datos para transferirlos al centro que se encuentra más cerca de nuestros clientes.

1.8.6 Asegura los datos en reposo y en tránsito

La seguridad de los datos cubre las siguientes dos áreas principales:

- **Confidencialidad:** Prevención del acceso no autorizado a los datos.
- **Integridad:** Asegurarse de que los datos no se modifican ni corrompen, se gestionan adecuadamente y la calidad de los mismos permanece.

Un data warehouse moderno también debe soportar el control de acceso basado en roles de múltiples niveles (RBAC o role based access control). Esto asegura que los usuarios tengan acceso sólo a los datos que se les permite ver. Para una mejor seguridad, se requiere una autenticación de factores múltiples (MFA o multi factor authentication). Con MFA, cuando un usuario se conecta, el sistema envía una solicitud de verificación secundaria, a menudo a un teléfono móvil. La clave de acceso enviada al teléfono debe entonces ser introducida. Esto asegura que una persona no autorizada con un nombre de usuario y una contraseña robados no pueda acceder al sistema. Como se observa es algo similar a como los bancos verifican que de verdad sea el cliente quien está ordenando una transferencia de dinero.

La gobernanza de los datos garantiza que se acceda a los datos de una empresa y que se utilicen adecuadamente, y que todos los datos se gestionen y se salvaguarden para frustrar las infracciones y cumplir con los reglamentos y protocolos definidos. También requiere una supervisión rigurosa para mantener la calidad de los datos. Los "datos malos", porque están corrompidos, son erróneos, inexactos o han sido falseados, pueden llevar a tomar decisiones de negocio erróneas o pobres, a la pérdida de ingresos y al aumento de los costes. Los administradores de datos - encargados de supervisar la calidad de los datos - pueden identificar cuando los datos son corruptos o inexactos, cuando no se actualizan con la suficiente frecuencia como para ser relevantes, o cuando se analizan fuera de contexto.




ENLACE DE INTERÉS

En el siguiente enlace se explica la importancia de la gobernanza de los datos.

<https://www.aepd.es/es/prensa-y-comunicacion/blog/gobernanza-y-politica-de-proteccion-de-datos>

Cifrar los datos, lo que significa aplicar un algoritmo de cifrado para traducir el texto claro en texto cifrado, es otra característica de seguridad requerida. Una parte también importante de la solución es la gestión de claves. Una vez que se encriptan los datos, se utiliza una clave de encriptación para descifrarlos. Además de proteger los datos, hay que proteger la clave que decodifica los datos. ¿Durante cuánto tiempo se debe usar la misma clave? ¿Qué sucede si la clave se ve comprometida? Todo esto debe ser gestionado para no rebajar los niveles de seguridad. El almacén de datos debe utilizar un enfoque jerárquico de envoltura de claves, que encripta las claves de cifrado, así como un proceso robusto de cambio de claves, que limita el número de veces que se utiliza una misma clave.

Además, el proveedor de soluciones de un data warehouse moderno a en la nube debe realizar pruebas de seguridad periódicas, conocidas como pruebas de penetración, para comprobar proactivamente la existencia de vulnerabilidades. El proveedor debe administrar estas medidas de manera consistente y automática, sin afectar al rendimiento de los sistemas que están en producción.



RECUERDA

Es recomendable elegir un data warehouse con un estándar de seguridad de extremo a extremo, prefiriendo una solución que haya pasado las auditorías de seguridad como SOC 1/SOC 2 Tipo II y ISO/IEC 27001.

1.8.7 Agiliza la línea de datos

La canalización de datos se refiere principalmente a los procesos de extracción, transformación y carga (ETL) que importan datos al almacén y en un formato que soporta consultas. Un conducto de datos lento obliga tanto a los usuarios, como a los analistas, a pasar demasiado tiempo esperando para acceder a ellos. El rápido crecimiento de la diversidad, el número y el tamaño de los datos no relacionales que llegan de múltiples fuentes agrava el problema.

Un almacén de datos moderno debería reducir la complejidad general del proceso para que los datos pasen más rápidamente por la tubería de datos sin que se formen cuellos de botella. Las soluciones modernas deberían ser capaces de cargar eficientemente datos semiestructurados en su formato nativo y ponerlos inmediatamente a disposición para su consulta sin

necesidad de sistemas adicionales e intrincados, como el NoSQL, para transformar los datos. Esto permite a los usuarios acceder inmediatamente a los datos de la misma manera que consultan una base de datos SQL. Esas soluciones pueden facilitar el acceso a nuevos datos de manera exponencialmente más rápida, reduciendo el proceso de ingesta y transformación en un orden de magnitud que puede ir de un día a menos de una hora.

1.8.8 Optimizar el tiempo de valorización

El despliegue de una solución no debería ser un proyecto de gran envergadura y los aspectos cruciales que antes eran manuales deberían automatizarse en los nuevos enfoques de data warehouse. Sobre todo, la solución que se elija debería estar disponible en todo momento, para todos los usuarios y abarcar todos los tipos de datos a una fracción del coste de los sistemas tradicionales. Un sistema de ese tipo debería proporcionar una comprensión inmediata de los datos para ayudar a racionalizar la organización usuaria y aumentar su capacidad para atender a los clientes y convertirse, gracias a los datos, en un referente de mercado.

Cuando una empresa está estudiando el mercado de data warehouse, para implantar uno por primera vez o para sustituir el antiguo por un nuevo almacén de datos más moderno, la primera opción a considerar es dónde quiere que se ubique su almacén de datos, pudiendo ser el centro de datos de la propia organización o la nube bajo un modelo de software como servicio (SaaS).



SABÍAS QUE...

El término "SaaS" fue acuñado por John Koenig para el SDForum Software como una conferencia de servicio en marzo de 2005 y se ha convertido en el término de referencia adoptado por la industria, que generalmente reemplaza los términos anteriores "A pedido" y "ASP" (Aplicación Proveedor de servicios).

El almacenamiento de datos tradicional (on premise), es una tecnología madura y muy probada, diseñada mucho antes de que la nube se convirtiera en una plataforma viable. Con la rápida adopción de la nube, surge la necesidad de soluciones de almacenamiento de datos que puedan aprovechar al máximo lo que ofrece. Vamos a estudiar las consideraciones clave para el almacenamiento de datos en la nube, comparándolo con los sistemas tradicionales on premise.



ENLACE DE INTERÉS

En el siguiente artículo se compara Cloud Data Warehouse vs Data Warehouse On premise

<https://www.beservices.es/cloud-data-warehouse-vs-data-warehouse-onpremise-n-5389-es>

1.8.9 Evaluando el coste/valor del tiempo

El despliegue de un almacén de datos convencional puede llevar por lo menos un año y extenderse a un proyecto de varios años antes de que se extraiga información valiosa de los datos. La agilidad de los negocios de hoy en día significa que los principales interesados que apoyan el proyecto (stakeholders en términos ya conocidos de la gestión de proyectos) y los principales habilitadores comerciales y técnicos responsables del éxito del proyecto, podrían abandonar el equipo o la empresa antes de que el proyecto se ponga en marcha. Un ciclo tan largo también expone el proyecto a recesiones económicas, a la caída de ingresos de la empresa y al riesgo de no poner nunca en marcha el proyecto debido a la ampliación de su alcance.

1.9 Comparación de soluciones de almacenamiento de datos en la nube

Cuando se pretende realizar un análisis objetivo para determinar qué solución de almacenamiento es la más adecuada para su uso en la nube, son varios los aspectos que se deben comparar buscando un equilibrio entre ellos:

- Los factores que afectan rendimiento
- Elegir una solución que garantice la protección y la seguridad de los datos
- Evaluar los ahorros en los costes, especialmente en aquellos que en muchas ocasiones quedan ocultos o no se les presta la atención que merecen, como los derivados de la administración de sistemas

La creciente adopción de la nube ha hecho que tanto los proveedores tradicionales on premise como los competidores recientemente llegados al

mercado, ofrezcan versiones en la nube de sus productos de almacenamiento de datos. Por tanto, la oferta de tecnologías para implantar un data warehouse es creciente y cada vez resulta más difícil encontrar diferencias entre aquellos fabricantes que llevan años en el mercado y lo que son de última generación.



EJEMPLO PRÁCTICO

Un equipo de amigos y compañeros de estudios que son expertos en el sector del transporte ha decidido lanzar una start up que pretende transformar el mercado de la logística ultrarápida en su pequeña ciudad.

Están convencidos de que su ciudad es tan pequeña que los grandes competidores como Amazon, nunca llegarán o, si lo hacen, tardarán años en posicionarse en dicha ciudad y ser capaces de hacer entrega de productos en menos de dos horas desde la compra.

Por supuesto, como expertos que son en ese sector tienen claro que necesitan una gran capacidad de análisis para planificar las rutas, analizar los clientes, establecer planes de mejora, etc. pero no saben por dónde comenzar. ¿Cómo lo solucionarías?

Solución

Dado que son una start up y que, por tanto, no contarán con grandes recursos o, en caso de tenerlos, preferirán destinarlos a marketing y captación de clientes, sin duda un data warehouse en la nube es la mejor opción para esta start up.

Pero no solo es cuestión de coste, sino que también se trata de la rapidez. Una start up necesita ser más rápida que una compañía ya establecida y con un data warehouse in situ nunca conseguirían esa velocidad.

Además, al ser una joven compañía es de suponer que no tienen el lastre de ningún sistema heredado, por lo que lo ideal es construir directamente en la nube para poder evolucionar e innovar mejor, por ejemplo, creando mercados de datos.


1.9.1 Comprensión de los enfoques del almacenamiento de datos en la nube

Existen diferentes enfoques de la nube a la hora de albergar datos, que difieren significativamente en como ofrecen sus capacidades de almacenamiento:

- **Infraestructura como servicio (IaaS):** Requiere que el cliente instale el software tradicional de almacenamiento de datos en los servidores proporcionadas por el proveedor de la nube. El cliente maneja todos los aspectos del hardware en la nube junto con el software de data warehouse. Las capacidades del almacén de datos, por tanto, serán idénticas a las que tendría el mismo software desplegado en un modelo on premise. Por tanto, es la alternativa más potente pero también la más compleja, porque todavía son muchos los aspectos que siguen siendo responsabilidad del usuario porque no han sido externalizados al proveedor de la nube.
- **Plataforma como servicio (PaaS):** Con este enfoque híbrido, el proveedor del almacén de datos proporciona el hardware y el software como un servicio en la nube y es él quien gestiona el despliegue de hardware, la instalación del software y la configuración del mismo. El cliente, por su parte, gestiona, adapta a sus necesidades y optimiza el software.
- **Software como un servicio (SaaS):** El proveedor de data warehouse proporciona todo el hardware y el software, incluyendo todos los aspectos de administración del hardware y el software. Normalmente se incluyen en el servicio elementos complementario como actualizaciones de software y hardware, seguridad, disponibilidad, protección de datos y optimización. Por tanto, es el extremo contrario al IaaS, donde casi todo el esfuerzo recae en el proveedor de la nube y el usuario ha externalizado prácticamente todas las funciones técnicas.

En todos estos escenarios, la tarea de comprar, desplegar y configurar el centro de procesamiento de datos, con todo lo que ello implica, como la adquisición del hardware para soportar el almacén de datos, se transfiere del cliente al proveedor. Más allá de esa ventaja que es común a los tres enfoques, los beneficios y desventajas de las diferentes ofertas varían en cuanto a la facilidad de uso, la seguridad y la disponibilidad.

Si un proveedor de data warehouse se limita a proporcionar acceso a su almacén de datos tradicional a través de la nube, es probable que la solución ofertada se asemeje a la arquitectura y funcionalidad originales que se tenían en la instalación on premise. Esto es limitante, porque reduce los beneficios potenciales de la nube, pero también presenta como ventaja que si ya somos usuarios de un determinado data warehouse, la migración hacia la nube puede resultar trivial.



VIDEO DE INTERÉS

En el siguiente vídeo se explican los modelos de servicio cloud IaaS, PaaS, SaaS.


<https://www.youtube.com/watch?v=VR8aXePkQ5M>

1.9.2 Comparando arquitecturas

Muchos proveedores ofrecen un almacén de datos en la nube, originalmente diseñado e implementado para entornos locales. Estas arquitecturas tradicionales fueron creadas mucho antes de que la nube surgiese y sus beneficios emergieran como una opción viable. Como alternativa, cualquier solución de data warehouse construida para la nube debería capitalizar los beneficios de la nube al máximo y no quedarse simplemente en una migración de un CPD local a un CPD en la nube. Para identificar si una solución construida está optimizada y cuenta con una arquitectura ad hoc para la nube, hay que tener en cuenta las siguientes características:

- Ofrece almacenamiento centralizado de todos los datos
- Escalado independiente de los recursos de computación y almacenamiento
- Satisface la concurrencia casi ilimitada sin que surja la competencia por los recursos ni se formen cuellos de botella ni cola de procesamiento.
- Facilita el cargar y consultar los datos simultáneamente sin degradar el rendimiento
- Replica los datos a través de múltiples regiones y nubes diferentes para mejorar la continuidad del negocio y simplificar el crecimiento del negocio
- Facilita el compartir datos sin necesidad de definir APIs o establecer procedimientos de ETL. O, cuando menos, el uso de APIs y ETLs se convierte en la excepción y no en la norma
- Cuenta con un servicio potente de metadatos que se aplica en todo el sistema. (Los metadatos son datos sobre otros datos, como el tamaño de cada archivo, autor o fecha de creación). Este catálogo de datos facilitará la explotación de los mismos y ayudará en la gobernanza global del sistema.
- Una arquitectura optimizada para la nube también aprovecha el almacenamiento como servicio, de modo que el almacenamiento de datos se expande y se contrae de forma automática y transparente

para el usuario. El almacenamiento de datos diseñado para arquitecturas más antiguas es costoso y tiene una escalabilidad limitada.




Comparativa entre arquitecturas nativas para la nube y arquitecturas tradicionales

Fuente: elaboración propia

1.9.3 Evaluación de la gestión de la diversidad de datos

Un factor clave que impulsa la adopción del almacenamiento de datos en la nube se deriva del creciente volumen de datos que se originan en la propia nube. Es decir, si cada vez más datos se producen fuera de la empresa, qué sentido tiene intentar integrarlos todos en un CPD interno. En la mayoría de los casos, estos datos no relacionales deben ser transformados antes de ser cargados en un almacén de datos tradicional, sea on premise o en la nube. Este enfoque añade una complejidad significativa y retrasos en el acceso a los nuevos datos.

Por tanto, con este mayor volumen y variedad de datos, la nube se ha convertido en un punto de integración natural. Una forma ideal de abordar este problema es con un data warehouse en la nube que pueda manejar tanto datos relacionales como no relacionales y sin tener que transformar los datos no relacionales o comprometer el rendimiento durante las etapas de carga de datos o de procesamiento de consultas.

**RECUERDA**

Los datos deben ser transformados antes de ser cargados en un data warehouse tradicional basado en la nube. Además, si necesitamos manejar de manera nativa datos no estructurados, será necesario comprar y mantener un sistema adicional NoSQL.

1.9.4 Elasticidad

No todos los data warehouse en la nube tienen la misma capacidad en cuanto a elasticidad. Las soluciones avanzadas pueden escalar hacia arriba y hacia abajo, sobre la marcha, y sin desconectar el sistema ni ponerlo en modo de sólo lectura.

Por este motivo, hay que contemplar en el análisis que se realice los inconvenientes de las soluciones que no escalan bien:

- Un almacén de datos en la nube que requiere una reconfiguración manual implica la necesidad de establecer una cuidadosa planificación y coordinación con el proveedor para escalar los recursos.
- El escalado puede requerir un tiempo de inactividad o un cambio al modo de sólo lectura para redistribuir los datos y reconfigurar el sistema. Durante ese periodo de tiempo el sistema no estará accesible para los usuarios o, aun estando disponible, la capacidad y funcionalidad del mismo será limitada.
- La mayoría de los almacenes de datos en la nube ofrecen paquetes o planes de procesamiento y almacenamiento en el mismo nodo, lo que requiere que los clientes escalen tanto si necesitan aumentar sólo uno o el otro, lo que redundará en un coste económico muchas veces innecesario.



ENLACE DE INTERÉS

En el siguiente enlace se muestra de forma práctica como la plataforma para big data Amazon EMR es elástica al implementar varios clústeres y al adaptar el tamaño de un clúster en ejecución.

<https://aws.amazon.com/es/emr/features/>

1.9.5 Comparación de las capacidades de concurrencia

La concurrencia es la capacidad de realizar dos o más tareas de forma simultánea o de permitir que dos o más usuarios accedan a una misma plataforma informática al tiempo. En un almacén de datos tradicional, los recursos fijos de computación y de almacenamiento limitan la concurrencia. Sin embargo, con la nube, la computación y el almacenamiento no son fijos.

Las arquitecturas optimizadas para la nube apoyan la concurrencia de las siguientes dos maneras:

- Múltiples usuarios pueden consultar los mismos datos simultáneamente sin degradar el rendimiento.
- La carga y la consulta pueden realizarse simultáneamente, lo que permite realizar múltiples cargas de trabajo simultáneas sin que se produzca un bloqueo de los recursos.

1.9.6 Garantizar el uso de SQL y otras herramientas


Casi todas las herramientas de inteligencia de negocios o business intelligence, particularmente las denominadas de extracción, transformación y carga (ETL) así como las de análisis de datos, pueden comunicarse con un cualquier data warehouse que soporte el estándar SQL, que solía ser lo común hasta los tiempos más recientes.

Sin embargo, no todas las soluciones de almacenamiento de datos en la nube son totalmente compatibles con el SQL estándar en el momento actual del mercado de software. Por ejemplo, muchas de las grandes soluciones de datos posicionadas como data warehouse en la nube suelen ser soluciones NoSQL y suelen tener soporte para SQL incompleto o no estándar o no compatible del todo. Aunque contar con estas herramientas analíticas más modernas es importante, SQL sigue siendo el estándar de la industria para la

consulta de datos. Por este motivo es recomendable elegir un data warehouse compatible con las herramientas SQL para la gestión de datos, la transformación de datos, la integración de datos, la visualización, la inteligencia de negocios y otros tipos de análisis.

1.9.7 Verificar que ofrece soporte para el respaldo y la recuperación

Con las soluciones de almacenamiento de datos en la nube y también con muchas de las que son on premise, los clientes deben proteger sus propios datos con herramientas de copia de seguridad y de recuperación de datos. Sin embargo, algunas soluciones de almacenamiento de datos en la nube incluyen la protección de datos como parte del servicio, lo que incrementa los niveles de seguridad y reduce las complejidades de la administración de los sistemas.



RECUERDA

Para una protección óptima, es recomendable optar por una solución que guarde automáticamente las versiones previas de los datos o que duplique automáticamente los datos para utilizarlos como copia de seguridad en línea. La solución de data warehouse elegida también debería permitir la recuperación sencilla, mediante mecanismos de autoservicio de los datos que se puedan haber perdido o que se detecte que están corrompidos mediante la replicación entre regiones dentro del mismo proveedor de nube o entre múltiples proveedores de nube. Esta flexibilidad añadida facilita una mejor continuidad del negocio incluso en el caso de los desastres más graves.

1.9.8 Verificar la resistencia y la disponibilidad

La resistencia es la capacidad del data warehouse para seguir funcionando automáticamente cuando se produce el fallo de un componente de un servidor, o de la red de comunicaciones o incluso de todo un centro de datos.

La disponibilidad es la capacidad que tienen los usuarios de acceder al sistema en todo momento conocido como tiempo de funcionamiento o tiempo en línea o, en inglés, uptime. Los servicios de data warehouse en la nube varían en cuanto a la medida en que el cliente es responsable de la disponibilidad y la resistencia. En el nivel más básico, un servicio de almacenamiento de datos

en la nube puede requerir que el cliente se encargue de la vigilancia del sistema para detectar y posiblemente prevenir un fallo. El cliente también puede tener que administrar la replicación de datos, de modo que una copia duplicada del almacén de datos esté disponible en caso de fallo. En el otro extremo del espectro de servicios disponibles actualmente en el mercado, el proveedor proporciona la vigilancia, la replicación y la conmutación automática en caso de error como parte del servicio.

La disponibilidad también es un factor a tener en cuenta respecto de las actualizaciones de los programas informáticos. Diferentes proveedores adoptan diferentes enfoques durante la actualización:

- **Básico:** Los clientes administran las actualizaciones y el tiempo de inactividad relacionado. Por ejemplo, decidiendo en que horario es menos perjudicial para los usuarios llevar a cabo la actualización.
- **Medio:** El proveedor gestiona las actualizaciones e informa a los usuarios de las próximas actualizaciones, para que puedan planificar el tiempo de inactividad, persiguiendo que afecta lo menos posible a la actividad laboral.
- **Óptimo:** El proveedor proporciona actualizaciones transparentes sin involucrar a los usuarios, ni someterlos a ningún tiempo de inactividad. El proveedor también permite a los clientes optar por las actualizaciones automáticas, para que puedan recibirlas cuando lo deseen. De esta forma, las nuevas versiones del software, así como los parches y actualizaciones se instalan de forma completamente transparente para el usuario.



SABÍAS QUE...


El tiempo de disponibilidad o uptime, se suele establecer en lo que se denomina SLAs o service level agreement, es decir, los acuerdos de nivel de servicio que cada proveedor de nube negocia con sus clientes.

Para saber cuál es la fiabilidad de un servicio debemos fijarnos en cuántos "9" de disponibilidad tiene el data warehouse en la nube. Por ejemplo, 99,99% por ciento de tiempo de funcionamiento, implica que el proveedor se compromete a que solamente un 0,01% del tiempo el sistema no estará disponible. Lo que significaría que solo resultaría admisible que el sistema esté caído durante poco más de 50 minutos cada año. Si elevamos el nivel de servicio al 99,999 %, entonces solo se admite unos 5 minutos de caída del sistema al año.

Normalmente los SLAs implican algún tipo de penalización para el proveedor, de manera que, si se superan los umbrales, el proveedor deberá devolver dinero al cliente o, incluso, pagar una sanción extra para compensarlo. Como también es entendible, incrementar 9 a la disponibilidad implica una tarifa mucho más alta en el servicio contratado, por lo que tampoco tiene sentido exigir una disponibilidad más alta de la que sea necesaria para evitar incurrir en costes añadidos.

1.9.9 Optimizar el rendimiento

Una de las grandes promesas de la nube es la capacidad de disponer de enormes cantidades de recursos que se pueden pagar sólo cuando se necesitan. Ello nos lleva a buscar una solución de almacén de datos en la nube que pueda optimizar el rendimiento bajo demanda y que elimine el esfuerzo administrativo para incorporar nuevos recursos. Incluso, en muchas ocasiones, el proceso de aprovisionar nuevos recursos o de devolver los recursos que ya no se utilizan en la nube se puede automatizar totalmente, de modo que el administrador de sistemas humano no se tenga que preocupar de ello y sea el propio sistema de monitorización del data warehouse en la nube el que decide contratar o no recursos adicionales.

**RECUERDA**

Hay que evitar utilizar implementaciones de data warehouse que interrumpen o retrasan la actividad corriente del negocio cuando necesitan sumar o restar recursos. Algunas soluciones también requieren trabajo administrativo, como la redistribución de datos y el recálculo de metadatos, lo que también se debe evitar en la medida de lo posible.

**ENLACE DE INTERÉS**

En el siguiente enlace se explica cómo optimizar el rendimiento de una arquitectura de data warehouse

<https://blog.powerdata.es/el-valor-de-la-gestion-de-datos/cpmo-optimizar-la-arquitectura-de-un-data-warehouse>

1.9.10 Evaluación de la seguridad de los datos en la nube

La nube se percibe a menudo como menos segura que el almacenamiento de datos en local, sin embargo, esta sensación de falsa seguridad no suele ser cierta. Las soluciones en la nube han ganado cada vez más aceptación debido a la generalización de los centros de datos seguros, incluso muchos de ellos certificados bajo normativas muy rigurosas que ofrecen a las empresas niveles de seguridad equivalentes a los que por ejemplo se disponen en los entornos críticos como los militares. También ha ayudado a incrementar la percepción de seguridad en los centros de datos en la nube los cada vez más frecuentes incidentes de seguridad que atacan a los centros de datos de importantes empresas. Este tipo de incidentes como los ransomware o secuestro de la información, revelan que las empresas están muy comprometidas en su capacidad de asegurar sus propios datos.



PARA SABER MÁS

En el siguiente artículo puedes ver cómo las empresas tratan de utilizar el big data para luchar contra el ransomware.

<https://www.europapress.es/portaltic/empresas/noticia-panda-security-deloitte-anuncian-alianza-estrategica-contr-ransomware-basada-big-data-20171106142844.html>

Las ofertas de almacenamiento de datos en la nube transfieren la responsabilidad de la seguridad desde los centros de datos físicos propios hacia el proveedor de soluciones de la nube. Aunque hay que realizar un ejercicio de realismo y sinceridad y tomar las debidas precauciones, porque las características de seguridad varían entre los proveedores y, obviamente, no todos son igual de confiables. Por ejemplo, las siguientes son unas premisas que se suelen cumplir a este respecto:

- Las ofertas básicas de almacenamiento de datos en la nube proporcionan sólo algunas capacidades de seguridad, dejando cosas como la encriptación, el control de acceso y el monitoreo de seguridad en manos del cliente. Y en seguridad informática se suele cumplir esa máxima que dice que una cadena se rompe por el eslabón más débil. Es decir, que en este escenario si la empresa cliente no cumple con sus responsabilidades, de nada servirá haber trasladado los datos a la nube.
- Otras soluciones ofrecen características como la encriptación y los controles de acceso, que los clientes pueden activar, pero dejarían al sistema vulnerable si no se activan correctamente.
- Las ofertas de data warehouse en la nube que están más orientadas a la modalidad de software as a service incorporan más características de seguridad y proporcionan encriptación, gestión de claves de cifrado, rotación de claves, detección de intrusos y otras funcionalidades como parte del servicio.

1.9.11 Costes de la administración


Los almacenes de datos tradicionales requieren una cantidad significativa de tiempo, esfuerzo y experiencia por parte de los equipos del cliente. Según la complejidad del data warehouse, será necesario disponer de uno o varios administradores de bases de datos, conocidos por sus siglas en inglés DBA o database administrator, que deben aplicar parches y realizar actualizaciones

de software, particionado de dato, distribución, clusterización o balanceado de los mismos, administración de los índices para acelerar las consultas, administración de la carga de trabajo, análisis de las estadísticas de funcionamiento y rendimiento para detectar anomalías, administración y monitoreo de seguridad, copias de seguridad y replicación, ajuste y reescritura de consultas etc. Un perfil de DBA con la formación y experiencia adecuada para administrar los data warehouse más complejos suele ser un profesional de muy alto coste.

Las soluciones de almacenamiento de datos en la nube que se basan en tecnologías más antiguas, como las utilizadas históricamente en implantaciones on premise, todavía requieren que el cliente gestione todos estos aspectos, lo que eleva tremendamente las necesidades de recursos de tipo DBA. Por el contrario, las nuevas propuestas de plataformas almacenamiento de datos reducen o eliminan muchos de estos gastos de gestión a través de nuevos diseños, enfoques alternativos y la automatización de muchas de las tareas más costosas y recurrentes.

1.9.12 Habilitar el intercambio seguro de datos

Muchas empresas pueden mejorar sus operaciones aprovechando los repositorios, servicios y flujos de datos de terceros. Los métodos tradicionales de intercambio de datos, como FTP, APIs y correo electrónico, requieren que se copien los datos y se envíen a los usuarios. Estos métodos suelen ser engorrosos, costosos y arriesgados, porque se basan en compartir datos estáticos, que rápidamente se vuelven obsoletos y deben actualizarse continuamente con versiones más actuales, lo que provoca que el ciclo de intercambio de datos nunca finalice. Un data warehouse construido en la nube permite compartir datos en tiempo real, bajo un modelo de gobernanza establecido previamente y con unos niveles de confidencialidad e integridad muy seguros.



RECUERDA

Los métodos actuales de intercambio de datos permiten intercambiar datos en vivo, muchas veces en tiempo real, sin moverlos de un lugar a otro.

1.9.13 Permitir la replicación de datos a nivel mundial

La replicación de datos crea múltiples copias de los datos de un data warehouse en la nube. Tener este tipo de distribución de datos a nivel global no sólo es esencial para la recuperación ante desastres sufridos y garantizar la continuidad del negocio, sino que también resulta útil si desea compartir datos con una base usuarios a nivel global sin establecer mecanismos de ETL entre regiones. Es decir, en vez de tener que exportar los datos desde un data warehouse, por ejemplo, en Europa, para posteriormente cargarlos en otro data warehouse en Estados Unidos, podemos replicar en línea ambos data warehouse, cada uno de ellos situado geográficamente a miles de kilómetros de distancia.

Los principales proveedores de almacenes de datos permiten compartir fácilmente datos entre regiones geográficas y a través de múltiples nubes. Este es el caso que nos encontraremos si somos usuarios de las principales nubes empresariales, incluyendo Amazon Web Services (AWS), Microsoft Azure y Google Cloud Platform (GCP). Estas capacidades de replicación global amplían los mercados, facilitan la participación de socios y permiten un ecosistema más completo para el análisis y el intercambio de datos. También son mecanismos que pueden ayudar a cumplir con la legislación vigente. Pensemos, por ejemplo, que las leyes de proyección de datos que hemos analizado en este mismo curso, como el reglamento general de protección de datos de la Unión Europea establece restricciones geográficas sobre en qué países pueden estar almacenados los datos de cualquier ciudadano europeo.

1.9.14 Asegurar el aislamiento de la carga de trabajo


Un factor clave en la velocidad y el rendimiento de un almacén de datos es su capacidad para aislar las cargas de trabajo. Para ser eficaz, el almacén de datos en la nube debería permitir configurar fácilmente múltiples grupos de recursos informáticos (de diversos tamaños) para separar las cargas de trabajo de los usuarios y los procesos que deben ejecutarse para satisfacer cada carga de trabajo simultáneamente. Esto elimina los bloqueos, cuellos de botella y proporciona recursos dimensionados adecuadamente para cada carga de trabajo. Lo ideal sería que estas cargas de trabajo separadas accedieran a los mismos datos simultáneamente y que se activasen y desactivasen fácilmente, en función de las necesidades.

1.9.15 Habilitación de todos los casos de uso

En los entornos tradicionales, diferentes sistemas de datos manejan diferentes casos de uso. Por ejemplo, un data warehouse tiene por misión la presentación de informes operacionales. Otro se utiliza para la presentación de informes y análisis departamentales (data mart). Al mismo tiempo, es

posible que en la empresa exista uno o varios lagos de datos (data lake) para la exploración de datos y el uso de herramientas especializadas para actividades como el análisis predictivo. Cada uno de ellos requiere un equipo informático, una copia de los datos, una gestión individual, etc. A simple vista, parece que no es la opción más eficiente.

Para reunir estos diversos casos de uso en la nube, un almacén de datos debe ofrecer formas rápidas y eficientes de clonar copias para generar múltiples cuadros de mando, esquemas y bases de datos, pero sin incurrir en riesgos añadidos ni en costes de almacenamiento mayores que los que tienen los mecanismos convencionales de duplicación de datos. Un data warehouse en la nube también debería facilitar la recuperación ante errores o problemas creados por transferencia de datos, así como garantizar la coherencia e integridad de los datos en el tiempo. Por ejemplo, con un mecanismo tan sencillo, pero tan poderoso como es el rebobinado, que habilita el acceso a versiones previas de los datos cuando la versión más actual no es correcta.



EJEMPLO PRÁCTICO

Una empresa de moda cuenta con un data warehouse desde hace aproximadamente quince años y los usuarios del mismo se han sentido bastante satisfechos con él.

Sin embargo, en los últimos tiempos, sobre todo desde el departamento de marketing y el de diseño de producto, se empieza a percibir que cada vez les cuesta más detectar las tendencias del mercado, anticiparse y crear ropa que los clientes desean.
¿Cómo lo solucionarías?

Solución

Esta compañía de la moda se ha sentido cómoda con su DWH porque tradicionalmente se han estado empleado datos estructurados para el análisis de clientes.

Por ejemplo, en su DWH con toda seguridad hay cargados muchos datos obtenidos del CRM, donde se puede analizar qué productos son más vendidos, cuales más rentables, que patrones de consumo tienen los clientes, que perfiles de consumidores son más interesantes, etc.

Y con la misma probabilidad, un data warehouse con quince años de antigüedad seguro que es incapaz de manejar datos no estructurados que son imprescindibles para una compañía de moda en la actualidad. Una empresa de moda necesita cargar sus DWH con datos como las opiniones vertidas en redes sociales sobre sus productos. Ya no es suficiente con analizar unas cuantas tablas extraídas de un CRM.

Por eso es el momento de que se plantee renovar su tecnología de almacén de datos e implantar uno que preste cobertura a todos los casos de uso.

1.10 Habilitar el intercambio de datos

Con muchas de las cuestiones que se han destacado hasta el momento, queda claro que la importancia del intercambio de datos en diferentes repositorios y data warehouse es cada vez mayor. Por este motivo, un diseñador o un arquitecto de soluciones de data warehouse debe:

- Reconocer la importancia del intercambio de datos.

- Establecer un intercambio eficiente de datos mediante un diseño adecuado de la arquitectura de sistemas.
- Saber aprovechar las oportunidades que ofrece el intercambio de datos para mejorar el negocio de la empresa usuario e, incluso, poder generar nuevos productos y servicios en base a ello.

La compartición de datos es el acto consistente en proporcionar acceso a los datos, tanto dentro de una misma empresa como entre empresas que han determinado que tienen activos informacionales que son valiosos para compartir. Por ejemplo, una empresa puede querer compartir datos con sus principales proveedores, socios, etc.

La organización que pone a disposición sus datos o comparte sus datos, se dice que es un proveedor de datos. La organización que quiere usar los datos compartidos se dice que es un consumidor de datos. Por este motivo nace el concepto que se denomina mercado de datos y del cual también se ha tratado con profusión en unidades previas de este curso.

Cualquier organización puede ser un proveedor de datos, un consumidor de datos o ambos. Además de todos los datos que las organizaciones generan y comparten entre sí, muchas mejoran sus operaciones aprovechando los repositorios, servicios y flujos de datos de terceros. Cada vez es más frecuente la filosofía del open data o datos abiertos que significa que tanto las empresas como las administraciones públicas facilitan que terceras partes puedan acceder y explotar sus datos.


Por ejemplo, una organización de servicios financieros como un banco, puede aprovechar diversos indicadores de mercado, financieros y económicos para crear mejores modelos de datos, que a su vez le ayudan a crear nuevas ofertas de productos para sus clientes. Estos datos pueden ser obtenidos a través de organismos como los bancos centrales de cada país, la Reserva Federal de Estados Unidos o el Banco Central Europeo, hablando de organismos públicos. Pero también puede ser datos proporcionados de forma abierta por empresas privadas como las bolsas de valores, los analistas de mercado u otros actores empresariales.

Hay un gran valor potencial que se puede liberar si se aprovechan adecuadamente las nuevas fuentes de datos alrededor de todo el mundo, tanto las que son accesibles internamente como las que se pueden obtener a través de los mercados y de los brokers y otros intermediarios de datos que ofrecen intercambios externos.

Sin embargo, hasta hace poco, no existía ninguna tecnología para compartir datos sin una cantidad significativa de riesgo, costes asociados y problemas varios, como la lentitud en el intercambio. Aunque el intercambio de datos

existe desde los inicios de la informática, todos los métodos hasta la fecha han sido limitados y han presentado algún tipo de inconveniente. Tal vez el intento más popular de facilitar el intercambio de datos a nivel informático ha sido el EDI o electronic data interchange, que ha tenido un mayor o menor éxito según el sector de actividad empresarial que se tome en consideración.

Imaginemos las posibilidades que se abren si todas las organizaciones pudieran tener acceso a repositorios que les permitiese satisfacer la demanda de datos que necesitan y que estos estuviesen siempre listos para ser utilizados, en tiempo real y pudieran hacer uso inmediato de ellos. Los datos ya no tendrían que ser exportados desde el proveedor de datos, trasladados al consumidor de datos y reconstruidos por el consumidor de datos para poder importarlos. Más bien serían accesibles instantáneamente y estarían listos para ser usados dentro de un ambiente seguro y bajo un modelo de gobernanza determinado. Aunque todavía queda mucho recorrido para que esa utopía sea 100% cierta, la realidad es que las tendencias de mercado apuntan inexorablemente hacia ello.



VIDEO DE INTERÉS

En el siguiente vídeo se introduce como el big data está transformando las finanzas.

<https://www.youtube.com/watch?v=vSbgCpyiybM>


1.10.1 Resolviendo los desafíos técnicos

Los métodos tradicionales de intercambio de datos, como el protocolo de transferencia de archivos a través de internet, más conocido por sus siglas en inglés FTP, el almacenamiento en la nube (Amazon S3, Box, Dropbox y otros), las interfaces de programación de aplicaciones (APIs) y el correo electrónico, requieren que se haga una copia de los datos compartidos por parte de los proveedores y se envíen a los consumidores de datos. Estos métodos no son óptimos porque producen datos estáticos, que rápidamente se vuelven obsoletos y deben ser actualizados con versiones más recientes, lo que requiere un constante movimiento y gestión de datos. Esto, como es previsible, dificulta las tareas de análisis porque, probablemente, cuando el analista o el científico de datos alcance una conclusión, esta deberá ser desechada porque los datos que han dado origen a la misma se han vuelto obsoletos o caducos.

Las nuevas tecnologías de intercambio de datos permiten a las organizaciones compartir fácilmente partes de sus datos y recibir datos compartidos, de manera segura y lógica. Se reducen o eliminan los movimientos físicos de datos. Se reduce también el uso de los softwares para la extracción, transferencia y carga (ETL). Ya no es necesario abordar actualizaciones constantes para mantener los datos frescos. No hay necesidad de transferir datos a través de FTP o de configurar las API para enlazar aplicaciones. Todo el proceso de aprovechamiento cruzado de los datos se realiza de una forma mucho más natural y, por tanto, más fluida.

Dado que los datos se comparten en lugar de ser copiados, no es necesario un almacenamiento adicional en la nube. Con esta nueva arquitectura, los proveedores de datos pueden publicar datos de forma fácil y segura para su descubrimiento, consulta y enriquecimiento instantáneo por parte de los consumidores de datos.

EFICIENTE ARQUITECTURA DE INTERCAMBIO DE DATOS



Una arquitectura eficiente para compartir datos en tiempo real.

Fuente: Elaboración propia

Un almacén de datos construido en la nube de los denominados multi tenant, es decir, que presta servicio a varios clientes de manera simultánea, proporciona la plataforma ideal para un servicio de intercambio de datos, porque permite a los miembros autorizados de un ecosistema en la nube aprovechar las versiones más actuales y de sólo lectura de los datos. Los proveedores de datos pueden compartir los datos con sus clientes, socios de la cadena de suministro, partners de logística y muchos otros agentes. Estas soluciones construidas en la nube aprovechan los últimos avances del cloud computing y el almacenamiento de datos. En lugar de transferir físicamente los datos a los consumidores internos o externos, el almacén permite el

acceso de sólo lectura a una porción del conjunto de datos en línea a través de SQL.

1.10.2 Lograr el éxito en el intercambio de datos

La mayoría de las organizaciones que inician su estrategia de intercambio y compartición de datos siguen un roadmap similar:

- **Colaboración interna:** Los datos se comparten dentro de la empresa entre sus unidades de negocio y filiales, mejorando la colaboración y descomponiendo los silos de datos. Esta primera fase es la más sencilla, puesto que se trata de un entorno que la propia empresa controla adecuadamente al ser interno a ella.
- **Perspectiva de negocios:** Se disponer de datos más completos gracias a la mejora en la colaboración y se impulsa una mejor comprensión del negocio, ya que el intercambio de datos se convierte en la norma.
- **Análisis de clientes:** La compañía realiza su tarea de análisis de cara al cliente, para mejorar el valor de un producto o servicio. Es el primer paso hacia la monetización de los datos. Para entender el concepto de monetización de datos pensemos en las plataformas de redes sociales que sin cobrar un solo euro a sus usuarios son capaces de ganar millones de euros.
- **Analítica avanzada:** A medida que los clientes solicitan más datos, la compañía desarrolla servicios analíticos personalizados, para proporcionar a los clientes mayor valor de sus datos.
- **Servicios de datos:** La empresa aprovecha los conjuntos de datos internos para ofrecer también a los clientes servicios de enriquecimiento, modelización y el análisis de datos. Para entender esta fase se puede recordar un caso de negocio descrito en este mismo curso que es el de la empresa de tasaciones inmobiliarias Tinsa, que además de su negocio tradicional que era cobrar a sus clientes una tarifa a cambiar de tasas su vivienda, en la actualidad ha creado una plataforma de datos que le permite vender otros servicios a otros clientes, en base a los datos que ha generado a lo largo del tiempo.
- **Intercambio de datos:** La empresa busca formas de mejorar sus productos basados en datos mediante la obtención de datos externos y ofrecer sus productos y servicios basados en datos a un público

más amplio, por lo general, a través de un mercado de datos o intercambio de datos. Un ejemplo de estos son las empresas de marketing digital que se dedican a crear perfiles de usuarios en internet para posteriormente vender ese valor añadido a aquellas empresas que quieren realizar campañas publicitarias.




Roadmap para el intercambio de datos.

Fuente: Elaboración propia

1.10.3 Monetizar los datos

La mayoría de las organizaciones, sobre todo las de tamaño medio y grande, ya comparten datos o tienen previsto hacerlo a corto y medio plazo. Pero lo que muchas no han conseguido todavía es encontrar la forma de monetizar sus datos, es decir, de convertir ese esfuerzo en un retorno financiero. Los analistas del mercado tecnológico coinciden en que hay un inmenso y creciente mercado para monetizar datos. Por ejemplo, en su informe de "Las predicciones para la transformación digital 2019" de IDC, esta firma de investigación predijo que el 80 por ciento de las empresas crearán capacidades de gestión y monetización de datos a partir del año 2020, y que para 2023, el 95 por ciento de las entidades habrán incorporado esta nueva estrategia digital.



RECUERDA

Con la arquitectura de intercambio de datos adecuada, se pueden analizar fácilmente más datos que nunca se había hecho en toda la historia, con el objetivo de descubrir y lanzar al mercado nuevos productos, servicios y negocios.



PARA SABER MÁS

Environics Analytics es una de las principales compañías de análisis de datos de Estados Unidos. Para proporcionar información basada en datos a sus más de 3.000 clientes, Environics ingesta y analiza grandes cantidades de datos demográficos, de localización y de patrones de consumo.

Hace un tiempo, Environics trasladó estas actividades analíticas a un data warehouse muy potente construido en la nube, que puede manejar prácticamente cualquier cantidad de datos y cualquier número de cargas de trabajo. Este data warehouse cuenta con un servicio de intercambio de datos incorporado, que permite a los clientes descubrir y obtener instantáneamente nuevos datos. Según Sean Howard, vicepresidente senior de desarrollo de productos de Environics, contar con un servicio seguro de intercambio de datos ofrece un mecanismo adecuado para la entrega de datos y genera inmensas oportunidades para aumentar los ingresos de la compañía. La plataforma en la nube se amplía o se reduce rápidamente para satisfacer las necesidades analíticas de cada usuario sin ayuda manual del equipo del departamento de informática, lo que eleva la flexibilidad de la plataforma al máximo.


Anteriormente, los científicos de datos de Environics almacenaban conjuntos de datos en sus ordenadores y compartían los productos informacionales e informes terminados con los clientes a través de FTP, lo que creaba una confusión interna y desmotivaba a los usuarios. La exploración de conjuntos de datos masivos que contenían miles de millones de filas de eventos requería el apoyo constante del equipo de tecnologías de la información para instalar el hardware necesario en cada momento, implantar entornos o granjas de servidores SQL, optimizar el rendimiento de las consultas y supervisar el uso de los recursos de almacenamiento y computación. Sin el equipo de ingeniería informática, era imposible que el sistema funcionase de una forma mínimamente adecuada.

Ahora, al disponer de un entorno analítico que escala según la demanda, permite a los científicos de datos realizar con confianza prototipos de grandes conjuntos de datos de cualquier negocio que quieran analizar, con independencia de las fuentes de información utilizadas o del tipo de archivo donde los datos estén albergados. Los analistas pueden convertir miles de millones de datos en bruto en informes muy interesantes. El servicio de intercambio seguro de datos aumenta la lealtad de los clientes, reduce los costes de cumplimiento normativo, privacidad, protección de datos... y elimina las transferencias de archivos innecesarias, a la vez que simplifica drásticamente la gestión de las versiones de los data sets al garantizar que siempre se está accediendo a la versión más reciente de los datos.

Las empresas de venta al por menor, los bancos, las entidades financieras, las empresas inmobiliarias, las organizaciones sin fines de lucro y los organismos gubernamentales utilizan el intercambio de datos para ayudarse a tomar

decisiones más informadas sobre los consumidores y los mercados, pasando de una gestión intuitiva a otra basada en evidencias empíricas.

Environics sigue siendo un ejemplo de empresa innovadora en el uso del data warehouse y está experimentando con los nuevos datos que se generan por el internet de las cosas (IoT) y otras fuentes de big data gracias a un servicio de ingestión continua de datos que agiliza la carga de los mismos y permite el análisis casi en tiempo real. "El intercambio de datos impulsará el crecimiento real del negocio y nos ayudará a poner nuestros datos a disposición de más clientes potenciales" es la afirmación de los responsables de esta empresa que recoge el informe de IDC.



EJEMPLO PRÁCTICO

Cuando un banco como BBVA comenzó a detectar que los clientes no querían pagar por tener una tarjeta de crédito, se vio obligado a encontrar una alternativa, porque mantener toda la infraestructura que se requiere en una red de pagos global es muy costosa: emisión de tarjetas, TPVs y su mantenimiento, comunicaciones, redes seguras, empleados, etc. ¿Cómo lo solucionarías?

Solución

La solución a este reto de negocio para BBVA pasó por la monetización de los datos. BBVA decidió tomar los datos de las compras de todos sus clientes y una vez anonimizados para respetar la ley y la privacidad de los usuarios, creó un sistema de análisis comercial que ofrece interesantes recomendaciones los establecimientos comerciales (tiendas, restaurantes, peluquerías, etc.) quienes están dispuestos a pagar una cuota elevada por utilizar un TPV de BBVA a cambio de disponer del servicio de análisis.

Se observa, por tanto, que con la monetización se ha conseguido incrementar los ingresos de un tipo de cliente (empresa) para compensar la reducción de ingresos de otro tipo de cliente (particulares).

1.11 Maximizar las opciones con una estrategia de nube múltiple

Como se ha indicado en varias ocasiones, utilizar de forma simultánea varias nubes, por ejemplo, la de Microsoft y la de Amazon, ofrece diversas ventajas que superar la complejidad de utilizar varios proveedores. Entre los beneficios aportados se encuentran:

- Reforzar la recuperación antes desastres y la continuidad del negocio
- Permiten la portabilidad entre las nubes, sin que el vendedor se quede casado con un único proveedor
- Facilitar las iniciativas de expansión internacional del negocio
- Simplificar la seguridad y la administración en entornos multi-nube

La creación de un data warehouse, que puede abarcar múltiples regiones y múltiples nubes, ofrece enormes ventajas para el intercambio de datos, la continuidad de las actividades básicas del negocio y la penetración en nuevos mercados geográficos.

Según el informe "2019 State of the Cloud" de Flexera, el 84% de las organizaciones tienen una estrategia multi-nube, que refleja esta realidad del mercado que estamos describiendo. Ya se trate de Amazon Web Services, Microsoft Azure o Google Cloud Platform, cada servicio de nube aborda necesidades ligeramente diferentes y también tiene funcionalidades mejor desarrolladas unos respecto de otros competidores.

Para las organizaciones que desean tener un alcance global desde su centro de almacenamiento de datos, una estrategia de nube múltiple, que también se suele denominar como cross-cloud tiene mucho sentido porque permite el movimiento libre y seguro de los datos desde cualquier lugar del mundo, al tiempo que permite seleccionar los proveedores de almacenamiento en la nube que mejor se adapten a sus necesidades y que ofrezcan las tarifas más competitivas.

Por ejemplo, cada uno de los departamentos de una empresa puede tener requisitos para su nube diferentes. Tal vez un departamento requiera de una nube con costes de operación muy bajos, mientras que otro departamento de la misma empresa prioriza una nube que cuenta con servicios avanzados de inteligencia artificial o de machine learning.


En lugar de exigir que todas las unidades de negocios utilicen el mismo proveedor, una estrategia de nube múltiple permite que cada unidad utilice la nube que funcione mejor para ella. Si esta flexibilidad es importante para una empresa, entonces debe seleccionar un proveedor de software para data warehouse que admita varios entornos de nube y que ofrezca soporte sino para todos, sí que al menos para los principales fabricantes.

1.11.1 Particularidades de la nube múltiple

Para distinguir conceptos que a veces se confunden, diremos que multi-nube significa que se pueden almacenar los datos de la empresa en varias nubes diferentes. Mientras que nube cruzada significa que puede acceder a los datos

de todas esas nubes simultáneamente, migrar sin problemas las operaciones analíticas de una nube a otra y compartir datos entre las nubes. Por tanto, diremos que ese es el gran objetivo que se persigue en cuanto al almacenamiento de datos en las nubes, porque así se evita estar atado a un solo proveedor de nube. Esto es muy importante por muchos motivos, entre los que se encuentran:

- Es una ventaja estratégica para las empresas globales, porque no todos los proveedores de nube operan en todas las regiones. Es verdad que los principales operadores del cloud computing están implantados en casi todo el mundo, pero, por ejemplo, algunos de ellos todavía no cuentan con centros de datos en España, lo que obliga a los clientes españoles a crear su almacén de datos en CPDs ubicados en Francia, Alemania u otros países de la Unión Europea.
- Es útil si se adquiere una empresa que ha estandarizado su plataforma de datos en una nube diferente a la que se está usando. Pensemos por ejemplo cuando un banco compra a otra entidad financiera y que puede ocurrir que los data warehouse de cada empresa se encuentren en nubes diferentes lo que complicaría el proceso de fusión.
- Si se planea compartir o monetizar los datos, contar con varias nubes amplía la llegada al mercado y a nuevos clientes que se encuentren en países donde un proveedor de nube es más popular que otro.



RECUERDA

Elige siempre que sea posible un fabricante de software de data warehouse que haya hecho el trabajo de adaptar su tecnología al mayor número posible de nubes diferentes.

1.11.2 Aprovechamiento de la replicación global

La replicación de datos es el proceso de almacenamiento de datos en más de un lugar para garantizar la disponibilidad de los datos si se produce una interrupción del servicio en una región concreta. También es la tecnología de base que permite compartir datos entre regiones y nubes. Los almacenes de datos necesitan una tecnología avanzada de replicación de datos para

maximizar las opciones de despliegue regional, permitir la continuidad de las actividades de negocio y expandir las operaciones en todo el mundo.

La plataforma de data warehouse que elijamos debería hacer posible la replicación entre regiones y entre nubes, sin reducir o ralentizar las operaciones que se realicen en el data warehouse primario.

1.11.3 Minimizar la interrupción del servicio

La replicación de los almacenes de datos en la nube es muy importante para los escenarios de recuperación ante desastres críticos. En el caso de una interrupción, asegura que se puedan reanudar instantáneamente las actividades de procesamiento de datos, sin incurrir en ningún tiempo de inactividad. De forma sencilla diremos que, cuando un sistema cae en España, otro se levanta en Estados Unidos, de forma totalmente transparente para los usuarios que no tienen por qué ser conscientes del desastre que pueda haber ocurrido.

Sin embargo, sin la tecnología de replicación de datos adecuada, la restauración de los backups separados por miles de kilómetros para grandes almacenes de datos puede llevar horas o días. Por este motivo, el objetivo a alcanzar no solo es garantizar la recuperación de los datos, sino que esta se produzca en el mínimo tiempo posible para no generar pérdidas económicas ni de imagen.

Cuando se analizan y comparan proveedores, debemos preguntarles si admite el acceso y la recuperación instantánea de las bases de datos de cualquier tamaño, en cualquier nube y en cualquier región. Si se produce un desastre en una parte determinada del mundo, debería poderse acceder inmediatamente a los datos replicados en una región o servicio de nube diferente. Hay que tener muy claro este aspecto y verificar si el proveedor de data warehouse en la nube replica las bases de datos y las mantiene sincronizadas a través de las plataformas y regiones de la nube.

1.11.4 Gestionando nubes cruzadas

La portabilidad de los datos es un problema generalizado para todas las organizaciones que tienen grandes cantidades de información en sus bases de datos. Cada proveedor de nube pública tiene diferentes niveles de penetración regional. El traslado de datos y cargas de trabajo entre regiones geográficas y nubes es más fácil con una arquitectura de nubes cruzadas.

La portabilidad de los datos simplifica el cumplimiento de las normas cuando una empresa requiere que sus datos permanezcan dentro de un determinado

país o región. La fusión o adquisición de otra empresa que podría tener un proveedor de nube diferente también es más fácil en este caso.

1.11.5 Protección de los datos

A medida que una empresa crece, es posible que se desee localizar sus operaciones de procesamiento de datos dentro de las regiones en las que presta servicio. Tener una estrategia multi-nube da la flexibilidad de seleccionar la nube más potente en cada región, para que pueda establecerse una arquitectura que minimice la latencia, mantenga los requisitos de ubicación geográfica de los datos y cumpla con las leyes de protección de datos. Se podrán expandir las operaciones de la compañía a regiones remotas sin sacrificar el acceso a los datos, y se descubrirá el valor de contar con una única fuente de datos para toda la organización.

La replicación de datos también facilita el intercambio y la monetización de los mismos, así como la participación de los socios de negocio y los partners en el intercambio, todo ello sin dejar de respetar el principio fundamental del intercambio de datos, es decir, que los datos existen localmente en una sola fuente, desde la cual se puede acceder a ellos en lugar de moverlos.



ENLACE DE INTERÉS

En el siguiente enlace se compara la protección de datos en data warehouse on premise vs data warehouse en la nube:


<https://keyrusspainblog.com/2018/11/28/seguridad-y-proteccion-de-los-datos-on-premises-vs-cloud-data-warehouses/>

1.11.6 Simplificando la seguridad

Cuando se trabaja con múltiples nubes, ¿cómo se asegura que se apliquen las mismas configuraciones y procedimientos de seguridad a todos los proveedores de nube? ¿Será necesario resolver las diferencias que muestren los registros de auditoría y los registros de eventos de cada nube? ¿Tendrán los expertos en seguridad informática de la empresa que lidiar con diferentes conjuntos de reglas o manipular múltiples sistemas de gestión de claves para encriptar los datos?

La respuesta a estos y otros temores similares es contar con un mecanismo unificado que abarque todas las plataformas de la nube y simplifique todas

esas operaciones. Gracias a ello no se necesitará contratar a profesionales especializados en seguridad para cada nube. Muchas veces esta coordinación es proporcionada por el software de orquestación.



RECUERDA

La tecnología de replicación avanzada permite compartir fácilmente los datos entre muchas regiones y a través de diferentes proveedores de cloud computing, sin necesidad de establecer nuevos pipelines de datos, copiarlos o coordinar las diferencias que surjan en materia de seguridad. Esto amplía los mercados a los que la empresa se puede dirigir, facilita la participación de socios y crea un ecosistema amplio para analizar y compartir datos.



EJEMPLO PRÁCTICO

Un laboratorio de investigación y tratamientos dedicado a la terapia genética utiliza un data warehouse para almacenar multitud de datos de los estudios e investigaciones que realizan y poder llevar a cabo análisis de los mismos.

Al ser un sector muy especial, están sometidos a mucha regulación que, además, cambia por regiones. Es decir, no pueden capturar los mismos datos de todos los pacientes según el país donde vivan y tampoco pueden analizar los datos de forma equivalente porque los límites varían.

Esta situación genera muchos problemas. Desde un exceso de coste por la necesidad de mantener mecanismos de control y cumplimiento diferentes para cada país hasta errores graves en algunos diagnósticos a pacientes.

¿Cómo lo solucionarías?

Solución

Una tecnología de replicación avanzada puede ser una solución perfecta para los requerimientos de este laboratorio. Para ello, si no están ya en la nube, deberán estarlo y, concretamente, deben elegir el proveedor o proveedores de nube que ofrezca la mejor cobertura regional en aquellos mercados donde operan.

De esta manera, sin necesidad de definir canales de comunicación específico se puede replicar a cada región solo aquellos conjuntos de datos admitidos de forma totalmente segura.

1.12. Seguridad

Cuando se despliega un data warehouse en la nube, son varios los aspectos de seguridad que la plataforma debe satisfacer, entre ellos:

- Establecimiento de una seguridad integral de los datos
- Cumplir con las normas de privacidad
- Mejorar la retención, protección y disponibilidad de los datos

Como se ha anticipado, de forma general, se puede decir que las evidencias muestran que la seguridad de la nube es alta. En la mayoría de los casos, los datos corporativos están más seguros en la nube que en un CPD propio. Una encuesta de 2019 realizada a docenas de ejecutivos de TI por Deloitte determinó que más del 90% de las organizaciones ya confían en la nube para mantener sus datos a salvo. La seguridad de los datos y el gobierno de los mismos fueron los principales impulsores de las organizaciones para migrar sus datos a la nube según esta encuesta.

Los proveedores de SaaS en la nube sirven a miles o incluso millones de clientes cada día. Pueden permitirse por tanto invertir en los recursos necesarios para proporcionar una seguridad de datos extremo a extremo con la máxima solidez. Sin embargo, no todos los proveedores de nube, recordemos que se cuentan por miles, hacen el esfuerzo de asegurar los datos albergados. Por ello, en un análisis comparativo se ve que las capacidades de seguridad varían mucho.

La protección de los datos y el cumplimiento de las regulaciones pertinentes deben ser contemplados a la hora de definir la arquitectura, implementación y operación de un servicio de almacenamiento de datos en la nube. Todos los aspectos del servicio deben centrarse en la protección de los datos como parte de una estrategia de seguridad multicapa que tenga en cuenta las amenazas de seguridad actuales y futuras. Esta estrategia debe abordar las amenazas externas, el control de accesos, el almacenamiento de datos y la infraestructura física, junto con una vigilancia exhaustiva, alertas y prácticas de ciberseguridad contrastadas.



ENLACE DE INTERÉS

En el siguiente enlace se explican los riesgos que supone la implementación de un data warehouse y los controles para mitigarlos.

<https://core.ac.uk/download/pdf/267872273.pdf>


1.12.1 Cifrado de datos por defecto

Encriptar los datos significa aplicar un algoritmo de cifrado para traducir el texto en claro, que cualquier podría entender a simple vista, por un texto cifrado que, aunque sea revelado no permitirá su conocimiento. Esto es fundamental para la seguridad.

Cifrar los datos desde que salen de las instalaciones propias, a través de Internet, se puede hacer mediante una red privada virtual o VPN.

Cifrar los datos estáticos en el almacén, cuando se almacenan en el disco o cuando se insertan dentro de un objeto de la base de datos como una tabla o cuando se almacenan en caché dentro de un almacén de datos virtual, se puede realizar mediante el software apropiado o mediante hardware criptográfico lo cual ofrece unos resultados de rendimiento muy superiores. Las búsquedas y consultas que se realicen también deben ser encriptadas, porque la información en ellas contenidas puede ser tan sensible como cualquier otra de la almacenada en la base de datos. Todos estos elementos deberían estar incorporados en la propia nube y nunca ser considerados como una opción.

El proveedor también debe proteger las claves de descifrado que descifran los datos. Los mejores proveedores de servicios emplean una encriptación AES de 256 bits con un modelo de clave jerárquica. Este método encripta las claves de cifrado y fomenta la rotación de las claves, lo que limita el tiempo durante el cual se puede utilizar una misma clave, con lo cual los parámetros de seguridad se incrementan.

**RECUERDA**


Los datos de una organización probablemente residen en muchos lugares diferentes. Por tanto, hay que proteger y controlar el flujo de datos en cada punto débil. Todos los datos deben ser encriptados de extremo a extremo y de forma automática, tanto cuando se encuentra en tránsito como en reposo.

1.12.2 Aplicando el control de acceso

La seguridad de los datos es sólo un aspecto de la seguridad integral. Las violaciones de datos a menudo se deben a la elección de contraseñas débiles por parte de los usuarios y de los administradores, junto con el uso de procedimientos de autenticación rudimentarios. Un servicio de almacenamiento de datos en la nube siempre debe autorizar a los usuarios, autenticar sus credenciales y concederles acceso sólo a los datos a los que están autorizados a acceder que serán los mínimos imprescindibles para cumplir con sus tareas.

El punto de partida es el control de acceso basado en roles, que asegura que los usuarios solo puedan acceder a los datos que tienen permiso para ver. El control de acceso debe aplicarse a todos los objetos de la base de datos, incluyendo tablas, esquemas y cualquier extensión virtual del almacén de datos. Para máxima conveniencia y seguridad, el almacén de datos en la nube también debe proporcionar una autenticación multifactorial, que requiere una verificación secundaria, como un código de seguridad de un solo uso vez enviado al teléfono móvil del usuario, tal y como acostumbramos a hacer con nuestro banco o tarjeta de crédito al realizar compras por internet.

Los procedimientos de inicio de sesión único y la autenticación federada facilitan que las personas se conecten al servicio de almacenamiento de datos directamente desde otras aplicaciones. La autenticación federada centraliza la gestión de la identidad y los procedimientos de control de acceso, facilitando al equipo técnico la gestión de los privilegios de acceso de los usuarios.

**RECUERDA**

El proveedor del data warehouse en la nube no debería tener acceso a los datos de los clientes no encriptados, a menos que la empresa usuaria le conceda explícitamente ese acceso.

1.12.3 Parches, actualizaciones y vigilancia

Los parches de software y las actualizaciones de seguridad deben instalarse en todos los componentes de software pertinentes tan pronto como esas actualizaciones estén disponibles. El principal motivo de esto es prevenir ataques que han sido detectados en otros lugares y que el parche en cuestión es capaz de evitar.

El proveedor también debe desplegar pruebas de seguridad periódicas (también conocidas como pruebas de penetración o pentesting para detectar vulnerabilidades que previamente no habían sido identificadas). Esta prueba, para generar mayor confianza, pueden ser ejecutadas por parte de una empresa de seguridad independiente, para comprobar proactivamente la existencia de vulnerabilidades.

Las medidas de seguridad física en el centro de datos deben incluir controles de acceso biométricos, para que solamente personal autorizado pueda acceder. También es frecuente en centros de datos de máxima seguridad disponer de guardias armados y vigilancia por video para asegurar que nadie obtenga acceso por la fuerza. Todas las máquinas físicas y virtuales deben ser controladas con rigurosos procedimientos apoyados por softwares de auditoría, monitoreo y alerta. Como protección adicional, las herramientas de monitoreo de integridad de archivos aseguran que los archivos críticos del sistema no sean manipulados y las listas blancas de direcciones IP permiten restringir el acceso al almacén de datos sólo a las redes de confianza. Por ejemplo, que solamente desde el internet de nuestra empresa se pueda administrar el sistema. Una lista blanca es una lista de direcciones IP, o nombres de usuario o de correo electrónico o nombres de dominio desde los cuales se puede acceder a nuestra infraestructura en la nube.

Los eventos de seguridad detectados por los sistemas de vigilancia y ciberseguridad deben registrarse automáticamente en un sistema de información y gestión de eventos de seguridad, conocidos comúnmente como SIEM. Deberían enviarse alertas automáticas al personal de seguridad cuando se detecte una actividad sospechosa para que la compruebe y tome medidas

al respecto que es lo que se suele hacer desde los denominados SOC o security operation center y los NOC que son los network operation center.

1.12.4 Asegurar la protección, retención y redundancia de los datos

En caso de un percance, se debería poder restaurar o consultar instantáneamente las versiones anteriores de los datos en una tabla o base de datos dentro de un período de retención especificado, según lo establecido en el acuerdo de nivel de servicio (SLA) con el proveedor del data warehouse en la nube. En los casos más exigentes, cuando por cuestiones normativas sea necesario retener los datos de forma indefinida, esto debe ser posible.

Una estrategia de retención de datos completa debe ir más allá de la duplicación de datos dentro de la misma región o zona de la nube. Debería replicar esos datos entre múltiples zonas para obtener redundancia geográfica. Opcionalmente, la conmutación automática cuando ocurra un error a otras zonas puede garantizar la continuidad de las operaciones empresariales.

1.12.5 Requiere el aislamiento de los tenants

Si el proveedor de almacén de datos utiliza un entorno de nube multi tenant, en el que muchos clientes comparten la misma infraestructura física, hay que asegurarse de que cada cliente tenga un almacén de datos virtual aislado de todos los demás almacenes de datos para garantizar la confidencialidad.

Para el almacenamiento, este aislamiento debe extenderse hasta la capa de máquina virtual. El entorno de almacenamiento de datos de cada cliente debe estar aislado del entorno de todos los demás clientes, regido por directorios independientes y claves de cifrado únicas. Algunos proveedores también ofrecen redes privadas virtuales (VPNs) dedicadas y bridges o puentes desde los sistemas de un cliente hacia el almacén de datos en la nube. Estos servicios dedicados aseguran que los componentes más sensibles del almacén de datos estén completamente separados de los de los otros clientes.

1.12.6 Mantener la gobernanza y el cumplimiento

La gobernanza de los datos garantiza que se acceda a los datos de la empresa y se utilicen adecuadamente y que las prácticas cotidianas de gestión de datos cumplan todos los requisitos reglamentarios pertinentes. Las políticas de gobernanza establecen normas y procedimientos para controlar la propiedad y la accesibilidad de los datos. Los tipos de información que deben cumplir estas pautas incluyen información de tarjetas de crédito, números de seguridad social o dni, fechas de nacimiento, información de redes IP,

coordenadas de geolocalización y cualquier otro dato que sea considerado como dato personal por la legislación en vigor en cada país, especialmente aquellos más sensibles como los referidos a la salud o la religión.

1.12.7 Exigir certificados y certificaciones

El cumplimiento no se refiere sólo a cumplir con las prácticas de seguridad informática más rigurosas. También se trata de asegurar que el proveedor del almacén de datos pueda demostrar que tiene los procedimientos de seguridad necesarios. Las violaciones de datos pueden costar millones de euros para remediar el problema y dañar permanentemente las relaciones con sus clientes por una pérdida de imagen y confianza, por no hablar de las grandiosas multas que la ley, especialmente en Europa, impone a las empresas.

Las normas de certificación estándar de la industria verifican que los proveedores de la nube utilizan controles de seguridad adecuados. Por ejemplo, un proveedor de data warehouse en la nube debe demostrar que supervisa y responde adecuadamente a las amenazas e incidentes de seguridad y que cuenta con suficientes procedimientos de respuesta a incidentes.

ESTÁNDAR DE SEGURIDAD EN DATA WAREHOUSE



Estándar de seguridad en un data warehouse en la nube

Fuente: Elaboración propia

Hay que verificar que todo el tráfico de datos esté encriptado y sea seguro y que los proveedores de nubes contratados tengan todas las certificaciones pertinentes.


Además de las certificaciones estándar en tecnologías de la información como ISO/IEC 27001 y SOC 1/SOC 2 Tipo II, es recomendable verificar que el proveedor de nube también cumple con todas las regulaciones aplicables del gobierno del país donde reside nuestra empresa y del sector de actividad donde nos desarrollamos. Dependiendo del negocio de cada empresa, esto podría incluir certificaciones como PCI, HIPAA/Health Information Trust Alliance (HITRUST) y FedRAMP que es el Programa Federal de Gestión de Riesgos y Autorizaciones del gobierno de los Estados Unidos.

Hay que exigir pruebas, por ejemplo, solicitar que los proveedores de la nube nos proporcionan una copia de que están certificados para cada norma pertinente. Por ejemplo, el informe SOC 2 Tipo II verifica que los controles técnicos y administrativos necesarios han estado en marcha consistentemente durante, como mínimo, los últimos 12 meses. El certificado de cumplimiento del PCI-DSS revela si un proveedor almacena y procesa adecuadamente la información de las tarjetas de crédito de nuestros usuarios. Si manejamos información sensible sobre la salud de personas y tenemos actividad en mercados como Estados Unidos, debemos requerir que los proveedores cumplan con las pautas de la HIPAA.

El cumplimiento y los certificados prueban que un proveedor de data warehouse en la nube es serio y transparente en cuanto a la seguridad. De lo contrario, debemos desconfiar.

Los proveedores de nube también deben proporcionar pruebas de que los proveedores de software de terceras partes con los que trabajan cumplen con las normas y que realizan auditorías de seguridad con regularidad. Por ejemplo, de que serviría tener la máxima seguridad en una nube si después se está utilizando como sistema operativo una distribución de Linux que no es segura.


Los datos son tan seguros como lo sea el eslabón más débil de la cadena tecnológica, por lo que debemos asegurarnos de que todos los actores tienen en marcha sólidos controles de seguridad y cumplen con las prácticas de seguridad exigibles.

**RECUERDA**

Hacer bien la seguridad es caro y requiere conocimientos especializados. Las brechas de seguridad de los equipos, los fallos en la red y los percances de mantenimiento pueden resultar en la pérdida de datos o introducir inconsistencias en los mismos. Una práctica de seguridad integral abarca muchos aspectos.

El proveedor del almacén de datos en la nube debe tener procedimientos para protegerse contra la destrucción accidental o intencional. Algunos proveedores proporcionan capacidades de seguridad demasiado rudimentarias, dejando la encriptación, el control de acceso y la supervisión de la seguridad en manos de sus clientes. La seguridad debería ser la base del servicio de almacenamiento de datos y no debería obligarnos a hacer nada extra para asegurar sus datos más allá de elegir a los mejores proveedores posibles.

Un proveedor que es claro y transparente, que presenta por adelantado sus certificaciones en materia de seguridad es mucho más probable que tenga una política de seguridad sólida.



EJEMPLO PRÁCTICO

Una empresa especializada en análisis de perfiles comerciales ha recibido una llamada de un proveedor de cloud desconocido. Este proveedor les ha demostrado que cuenta con un SaaS de inteligencia artificial muy innovador. La empresa de análisis comercial está segura de que con la funcionalidad que han creado pueden convertirse en líderes absolutos de mercado.

El problema es que realizar perfilados masivos de clientes es uno de los temas que más exigentemente está regulado por el reglamento general de datos. Si desde el punto de vista de seguridad algo sale mal y se filtran estos datos, en vez de convertirse en líderes de mercado deberán pagar una sanción tan grande y su imagen quedará tan resentida que difícilmente podrían sobrevivir. ¿Cómo lo podrías solucionar?

Solución

La situación es compleja porque el beneficio potencial es inmenso, pero también lo es el riesgo.

Por este motivo deben exigir al nuevo proveedor de SaaS que les entregue copias completas de todos los certificados de seguridad que tienen, pero no solo de una hoja resumen o un sello. Debemos comprobar en detalle la validez de todos los documentos.

Será muy recomendable que el proveedor de cloud cuente con una norma ISO 27001, que es una norma internacional la cual permite el aseguramiento, la confidencialidad, así como también la integridad de todos los datos e informaciones albergadas y los sistemas de información utilizados en su procesamiento.

1.13 Minimizando los costes de un almacén de datos

Todos los requisitos técnicos, funcionales y de negocio que hemos descrito hasta el momento que nuestro data warehouse debe satisfacer, como es lógico, tienen que mantener un equilibrio con los costes. Es decir, si creamos un data warehouse muy flexible, muy seguro y funcional, pero extremadamente costoso, nunca podremos obtener un retorno de la inversión, lo que sería de todo punto de vista ridículo.

Desde un punto de vista económico los objetivos que debe satisfacer nuestro data warehouse en la nube son:

- Creación de un entorno de almacenamiento rentable
- Obtener el máximo valor añadido y rendimiento mediante la consecución de la mejor arquitectura posible al precio más bajo posible.

Vamos a ver como implementar un data warehouse construido en la nube y cómo podemos apoyarnos en los proveedores adecuados para rebajar los costes a largo plazo.

1.13.1 Minimizar el coste de almacenamiento

Cuantos más datos se puedan almacenar, mayor será la inteligencia y el conocimiento que se pueda obtener. Afortunadamente, el almacenamiento en la nube de Amazon, Microsoft y Google se ha vuelto relativamente barato, por lo que no deberíamos sentirnos limitados en la cantidad y tipos de datos que almacenamos. Debemos examinar los términos comerciales para asegurarnos de que nuestro proveedor de almacenamiento de datos en la nube no está fijando los precios de almacenamiento al alza.

Examinar los términos del acuerdo de condiciones de uso nos permitirá aclarar que sólo debemos pagar por el almacenamiento que se utilice, no por la capacidad de almacenamiento excedente o reservada. Tampoco deberíamos pagar por clonar bases de datos dentro de nuestro almacén de datos para actividades de desarrollo y pruebas. Deberíamos poder referenciar, no copiar, los datos varias veces y, por lo tanto, no deberíamos tener que pagar un extra por dicho almacenamiento.

Un almacén de datos en la nube también debería permitirnos almacenar y consultar datos estructurados y semi-estructurados como JSON. Por último, intentemos elegir un proveedor que ofrezca capacidades multi-nube, porque eso puede ahorrarnos costes futuros si queremos migrar nuestro almacén de datos a otro entorno de almacenamiento en la nube.

1.13.2 Maximizar la eficiencia de la computación

Los recursos de computación son más caros, cuando menos en el momento actual del mercado, que los recursos de almacenamiento, que han visto reducido su coste de forma drástica en los últimos años, como ya hemos mencionado a lo largo de este curso.

Por tanto, el servicio de data warehouse en la nube contratado debería permitir escalar cada recurso de forma independiente y facilitar la obtención

de los recursos de computación que necesitamos exactamente según un modelo de precios basado en el uso. El proveedor debería facturarnos sólo los recursos que utilizamos, segundo a segundo o transacción por transacción y desactivar automáticamente los recursos de computación cuando dejemos de utilizarlos, para evitar costes injustos. Las tarifas basadas en el uso frente a las basadas en la suscripción nos permiten elegir mejor la forma en consumimos los recursos.

Los términos flexibles también deberían permitirnos dimensionar correctamente nuestros clústeres de computación para cada carga de trabajo. Si estamos ejecutando un trabajo de extracción, transferencia y carga (ETL) con bajos requerimientos de computación, podríamos usar un pequeño clúster para esa carga de trabajo en lugar de incurrir en el coste de un clúster de alta potencia de cálculo. Sin embargo, si por ejemplo necesitamos probar un nuevo módulo de machine learning, podríamos utilizar un clúster grande o una máquina individual con múltiples procesadores y múltiples núcleos. Esto nos proporciona una escalabilidad adecuada y granular para cada carga de trabajo, a la vez que minimiza los costes de uso. El objetivo siempre es que el funcionamiento del DWH en la nube cueste menos que el equivalente on premise, que utilizan enormes recursos y producen resultados limitados. Las cargas de trabajo no se ralentizarán, ni siquiera se paralizarán, gracias a los clusters de computación dedicados a cada carga de trabajo.

1.14 Consejos prácticos para empezar un data warehouse en la nube

A modo de lista de comprobación o checklist, vamos a verificar en este apartado que aspectos debemos tener en cuenta antes de ponernos manos a la obra con la construcción de un data warehouse en la nube. Entre otros aspectos, deberemos:

- Enumerar las necesidades de nuestro almacén de datos y los criterios de éxito
- Considerar todos los factores del coste total de la propiedad
- Hacer un piloto del almacén de datos antes de invertir en recursos costosos

Si seguimos una serie de pasos clave a la hora de elegir un almacén de datos en la nube para nuestra organización, las probabilidades de éxito se multiplican. El proceso comienza con la evaluación de las necesidades de almacenamiento de datos y finalizará con la prueba de concepto de la opción seleccionada. Al final de todo, tendremos un plan para ayudarnos a elegir la mejor solución con garantías y llevarla a producción.

1.14.1 Paso 1: Evaluar las necesidades

El almacén de datos adecuado para cada empresa debe satisfacer las necesidades actuales y ser capaz de acomodar las necesidades futuras. Por lo tanto, es conveniente analizar la naturaleza de los datos que manejamos, las habilidades y herramientas ya existentes en nuestra organización, las necesidades de uso que tenemos, los planes de futuro del negocio y cómo un almacén de datos puede ayudarnos a crecer y ser más competitivos. Entre las preguntas que nos debemos formular se encuentran las siguientes:


- **Datos:** ¿Qué tipos de datos debe contener el almacén de datos? ¿A qué ritmo crecen los nuevos datos? ¿Con qué frecuencia se trasladarán los datos al almacén? ¿A qué datos cruciales no podemos acceder hoy, pero deseamos acceder con la nueva tecnología?
- **Encaja con las habilidades, herramientas y procesos existentes:** ¿Qué herramientas y habilidades de nuestro equipo se aplicarán o serán útiles para el nuevo almacén de datos? ¿Qué procesos se aplicarán al nuevo almacén de datos en la nube?
- **Uso:** ¿Qué usuarios y aplicaciones accederán al DWH? ¿Qué tipos de consultas se ejecutarán? ¿Cuánto datos deben ser accesibles por los usuarios, con qué frecuencia y con qué rapidez? ¿Cómo variará la carga de trabajo a lo largo del tiempo? ¿Qué rendimiento requieren los usuarios y aplicaciones que explotan los datos? ¿Cuántos usuarios deberían acceder al almacén de datos, pero no lo hacen hoy en día debido a las limitaciones de recursos?
- **Compartir datos:** ¿Se planea compartir datos de forma segura con clientes y/o socios? En caso afirmativo, ¿qué tipos de datos se compartirán?, ¿se creará un mercado de intercambio de datos para monetizarlos? ¿Permitiremos que estos consumidores de datos accedan a los datos en bruto, o también se pretende enriquecer esos datos ofreciendo servicios análisis?
- **Acceso global:** ¿Se planea almacenar datos en un almacén de nube pública, como Amazon S3, Microsoft Azure o la plataforma de nube de Google? ¿Tienen estos datos requisitos normativos que requieren respetarse? ¿Se necesita una arquitectura cross-cloud para maximizar las opciones de despliegue regional, para reforzar la recuperación ante desastres o para asegurar la continuidad del negocio?
- **Recursos:** ¿Qué recursos humanos están disponibles para gestionar el almacén de datos? ¿Cuánta inversión se desea hacer para supervisar y gestionar la disponibilidad, el rendimiento y la seguridad? ¿Se cuenta

con experiencia previa en el desarrollo y gestión de almacenes de datos o tenemos un equipo de DevOps para racionalizar este proceso de despliegue?

1.14.2 Paso 2: Migrar o empezar de cero

Cada proyecto de almacén de datos en la nube debería comenzar, en caso de que contemos con una infraestructura heredada (legacy systems), con la evaluación de cuánto del entorno existente se debería migrar al nuevo sistema y qué es lo que se debería construir de nuevo desde cero para crear el almacén de datos en la nube. Estas decisiones implican a todos los elementos de un DWH, desde el diseño de los procesos de extracción, transformación y carga (ETL) hasta los modelos de datos y los métodos del ciclo de vida del desarrollo de software que se quiera utilizar. Debemos contemplar los siguientes aspectos:

- ¿Es un proyecto nuevo? Si es así, a menudo tiene sentido diseñar el proyecto desde cero para aprovechar al máximo las capacidades de un almacén de datos en la nube, sin ninguna restricción, en lugar de llevar a cabo una migración de la aplicación existente que nos genere limitaciones.
- ¿Qué partes del sistema actual causan más problemas? Una migración bien planeada podría centrarse en trasladar las cargas de trabajo más problemáticas hacia el DWH en la nube. O tal vez se quiera migrar las cargas de trabajo más sencillas para obtener ganancias rápidas, convencer a los directivos y usuarios del valor del nuevo DWH y continuar el proceso de forma evolutiva. Aquí los aspectos políticos de la organización influyen en gran medida.
- ¿Qué aspectos del sistema actual presentan restricciones que ya no ocurrirán en una nube?
- ¿Cómo acceden los usuarios y aplicaciones actualmente al DWH? Por ejemplo, los usuarios y las aplicaciones que se basan en interfaces estándar (SQL) y que utilizan herramientas estándar de ETL y de inteligencia de negocio, tendrán menos problemas al adaptarse al nuevo enfoque.
- ¿Cómo es de probable que los requisitos de nuestros datos y tareas de análisis cambie en el futuro?

**RECUERDA**

Si tenemos un almacén de datos tradicional grande y complejo, se puede migrar una pequeña parte del sistema para que todo el mundo se sienta cómodo con el uso de un almacén de datos en la nube. Posteriormente se puede expandir iterativamente, utilizando metodologías ágiles, hasta que todo el DWH se lleve a la nube.

1.14.3 Paso 3: Establecer los criterios de éxito

Los criterios de éxito son indicadores objetivos que facilitan el medir como de bien o de mal se está desarrollando el proceso de construcción de nuestro DWH en la nube:

- ¿Cómo mediremos el éxito de trasladarnos a un nuevo almacén de datos en la nube? Para ello debemos elegir los requisitos funcionales y técnicos más importantes. Siempre debemos guiarnos por criterios centrados en el rendimiento, la concurrencia, y el costo total de propiedad (TCO).

Si el nuevo almacén de datos en la nube tiene capacidades que no estaban disponibles en el sistema anterior y esas capacidades son relevantes para evaluar el éxito comercial y técnico de la nueva solución, debemos asegurarnos de incluirlas. También hay que formar adecuadamente a los usuarios para que sepan utilizar estas nuevas características y que, por tanto, sean capaces de valorarlas en su justa medida.

Según se establezcan los criterios de éxito de la nueva solución, debemos comprobar y medir como los criterios están aportando al éxito del nuevo DWH, decidiendo qué criterios son cuantificables y cuáles son cualitativos, cómo medir los criterios cuantitativos y cómo evaluar los criterios cualitativos.



PARA SABER MÁS

White Ops es un proveedor líder en servicios de ciberseguridad. A diferencia de otros enfoques convencionales que emplean el análisis estadístico, White Ops combate la actividad delictiva en la red diferenciando entre la interacción robótica y humana, trabajando para descubrir y caracterizar nuevas pautas de fraude. Este proceso constante requiere el almacenamiento y el procesamiento de cantidades masivas de datos.

White Ops había basado su infraestructura previa para ello en sistemas NoSQL como MongoDB para almacenar y procesar esos datos. Sin embargo, la latencia de los resultados era de al menos 24 horas, dependiendo de la carga de trabajo de cada momento. Cuantas más solicitudes, más largos eran los retrasos. Esto era especialmente problemático en situaciones críticas, por ejemplo, cuando se producía un nuevo ataque a gran escala y se veían incapaces para analizar toda la información y dar respuestas adecuadas a sus clientes.

Para aumentar la productividad y el rendimiento, White Ops implementó un almacén de datos en la nube con SQL como lenguaje central y lo implementó como un servicio. El almacén de datos permite a White Ops tener todos los datos en un solo lugar, escalar de forma elástica, consultar datos diversos con SQL estándar y satisfacer mejor las necesidades de prevención del fraude que sus clientes esperan recibir.

White Ops puede ahora consolidar y escalar cantidades masivas de datos, permitir el acceso a los datos sin depender de especialistas con profundos conocimientos de programación y ayudar a sus clientes a evitar los efectos devastadores del fraude en línea.

1.14.4 Paso 4: Evaluar las soluciones

Una vez que determinemos las necesidades de nuestro almacén de datos y los criterios de éxito, estaremos listos para empezar a evaluar las soluciones. Al comparar soluciones alternativas, mantengamos en mente el objetivo perseguido que es cumplir con los siguientes criterios:

- Nuestro DWH aborda las necesidades actuales y futuras
- Integra datos estructurados y semiestructurados, almacena todos ellos en un mismo lugar y evita la creación de silos de datos
- Se apoya las habilidades, herramientas y conocimientos existentes
- Protege contra la pérdida de datos y permite una fácil recuperación de los mismos antes las desgracias más graves

- Asegura los datos mediante contraseñas robustas y los algoritmos de encriptación más solventes
- Asegura que los datos y los análisis estén siempre disponibles
- Racionaliza el pipeline de datos para que los nuevos datos estén disponibles para su análisis en el menor tiempo posible, con la mínima latencia posible
- Optimiza el tiempo de puesta en marcha, para que se puedan percibir los beneficios del nuevo almacén de datos lo antes posible
- Asigna recursos a cada carga de trabajo aislada, para no desperdiciar capacidades de computación de forma ridícula
- Comparte los datos sin tener que copiarlos o moverlos. Conecta fácilmente a los proveedores de datos y a los consumidores
- Replica las bases de datos y las mantiene sincronizadas a través de múltiples plataformas en la nube y distintas regiones geográficas para mejorar la continuidad del negocio y facilitar la expansión internacional
- Proporciona una copia de la base de datos de producción para el entorno de desarrollo y facilita los múltiples casos de uso que se puedan dar, como la presentación de informes, la exploración de datos y el análisis predictivo
- Facilita la recuperación de datos perdidos por errores o ataques al permitir retroceder a versiones anteriores
- El escalado de capacidad de cómputo y de almacenamiento se hace de forma independiente y automática, permitiendo crecer en concurrencia sin ralentizar el rendimiento.

1.14.5 Paso 5: Calcular el TCO


Si se elige un almacén de datos en la nube en función del precio, hay que tener en cuenta que el coste total de propiedad puede ser superior a la tarifa que se abona al proveedor de la nube.

Lo mismo ocurre en un almacén de datos convencional, cuyo coste total de propiedad incluye el precio de las licencias, a menos que se trata de open source y que normalmente está basado en el número de usuarios; el hardware (servidores, dispositivos de almacenamiento, redes); el centro de datos (espacio de oficinas, electricidad, administración, mantenimiento y gestión); la seguridad de los datos (protección mediante contraseñas y cifrado); las soluciones para garantizar la disponibilidad y la capacidad de recuperación; la compra de hardware adicional para la ampliación de recursos en momentos de alta concurrencia; y la creación de entornos de desarrollo y previos al paso a producción.

En el caso de algunas soluciones, tal vez sea necesario considerar costes adicionales, como el diseño y la gestión de uno o múltiples mercados de

datos, la obtención de varias copias de datos, la capacitación del personal, la utilización de múltiples sistemas (por ejemplo, SQL y NoSQL) para manejar diversos datos, etc. Y su sin fin de otros costes menores que en demasiadas ocasiones quedan ocultos.

El cálculo del coste total de las opciones de almacenamiento de datos en la nube suele ser más fácil, pero varía según el proveedor del servicio. Asumiendo que se subcontrata todo al mismo proveedor en modalidad ed almacenamiento como servicio (DWaaS), se puede calcular el TCO en base a la cuota de suscripción mensual. Si se opta por una solución de infraestructura como servicio (IaaS) o de plataforma como servicio (PaaS), como ya se ha mencionado en esta misma unidad, se deberán sumar los costes del software, la administración y los servicios que la solución no incluya.



RECUERDA

Las organizaciones normalmente calculan el TCO sobre el tiempo de vida esperado del almacén de datos, es decir, sobre el horizonte de tiempo que se considera que dicha inversión va a ser utilizada, que suele ser de uno a tres años. Esto no tiene por qué ser así en tiempos tan dinámicos como los actuales y tal vez la plataforma adquirida se quede obsoleta antes de lo previsto.

Otra advertencia clave es que a menudo se asume que un sistema en la nube funciona las 24 horas del día, los 7 días de la semana a su máxima capacidad, pasando por alto los ahorros posibles que se obtienen gracias a que una solución en la nube se amplía y se reduce dinámicamente en respuesta a los cambios en la demanda y sólo se paga por segundo o por transacción.

1.14.6 Paso 6: Establecer una prueba de concepto (POC o proof of concept)

Después de investigar las diferentes opciones de data warehouse en la nube, probar las demos que están disponibles, hacer consultas y reunirse con el equipo de cada proveedor, es recomendable en cualquier sistema de información tan complejo, tan crítico y costoso como este, hacer una prueba de concepto (PoC) antes de elegir de forma definitiva.

Una PoC consiste en hacer prueba real de una solución para determinar cómo de bien satisface las necesidades identificadas y cómo cumple con los criterios de éxito que se hubiesen fijado. Normalmente dura unos pocos días, pero puede ser que se extienda según complejidad a lo largo de varias semanas.


Solicitar una PoC implica un coste al proveedor, por lo que habrá que negociar un acuerdo con él para realizarla. En ocasiones, el proveedor la realizará sin un coste económico específico, pero con el compromiso de que, si la solución funciona satisfactoriamente, se le comprará el producto o se le contratará el servicio. En otras ocasiones, el proveedor puede exigir un pago que cubra todo o parte del coste de tiempo que va a dedicar a preparar junto con nosotros la prueba de concepto.



SABÍAS QUE...

Al definir una PoC, hay que enumerar y compartir con el proveedor todos los requisitos y criterios de éxito, no sólo los problemas que se trata de resolver con el nuevo DWH, sino detallar todo lo que sea posible como queremos que sea la nueva solución en la nube. Elaborar una lista de verificación exhaustiva de las necesidades que satisfará el DWH y sus criterios de éxito es un buen punto de partida para comenzar a trabajar con el proveedor en la prueba de concepto.

Hay que asegurarse de que el nuevo almacén de datos cumpla todo lo que el actual DWH hace, pero mejor y que en la PoC quede demostrado que supera los inconvenientes que se hubiesen identificado en el sistema heredado. Si se hace una PoC con varios proveedores, se debe utilizar la misma lista de verificación para cada uno de ellos para que el análisis y evaluación de proveedores sea objetivo y todos compitan bajo las mismas reglas.



EJEMPLO PRÁCTICO

Siendo el informático asignado al departamento financiero de la empresa donde trabajas, te han pedido que definas una estrategia para que la dirección general apruebe un presupuesto para poner en marcha un data warehouse. Una vez presentada la propuesta al comité de dirección, la respuesta no es la deseada.

Vuestra solicitud de presupuesto era de 1.000.000 €, pero desde la dirección general solo os han aprobado 200.000 € y realmente no sabéis qué hacer. Incluso estáis pensando en renunciar al presupuesto y olvidar el proyecto.

¿Cómo lo podrías solucionar?

Solución

Renunciar al presupuesto en este momento probablemente genere en la dirección general la impresión del construir un almacén de datos no era tan importante. Como derivada, difícilmente en los próximos años recibiremos presupuesto para ello.

Intentar crear un data warehouse en las mismas condiciones, con una reducción tan grande de presupuesto, probablemente provocará que el resultado sea peor que el esperado y la dirección general no dote presupuesto para continuar con él en siguientes ejercicios.

Por tanto, la alternativa más inteligencia sería negociar una prueba de concepto con un proveedor adecuado para de ese modo poder presentar a la dirección general una muestra de lo que se pretende obtener y renegociar un incremento presupuestario.



VIDEOTUTORIAL

En este video tutorial conoceremos como implantar un data warehouse en la nube mediante la plataforma de Snoflake.

<https://vimeo.com/user64513894/review/490485645/506c644717>

2. VENTAJAS Y DESVENTAJAS

En el caso que estás resolviendo en esta cadena de supermercados, la realidad es que la decisión al respecto de on premise o cloud está muy claramente decantada hacia la segunda.

En un negocio como este de supermercados, los data warehouse tienden a presentar cargas de trabajo importantes. Por ejemplo, en los periodos como navidad o rebajas, habrás picos de cargas de trabajo a los cuales será necesario responder de modo homogéneo.

Por otra parte, como ya eres consciente, tu empresa se relaciona con cientos de proveedores, con los que debe estar cada día más coordinada. Por ello, una vez que se haya superado este primer momento más crítico, será muy interesante crear un mercado de datos, donde proveedores y nosotros podamos compartir datos para, por ejemplo, desarrollar conjuntamente nuevos productos que resulten más atractivos para los clientes.

Otro factor que incide en el interés de adoptar la nube es que las empresas del retail suelen tener sistemas muy pesados tanto en materia de ERP, como de SCM. Desde la nube, a medio plazo, se podría plantear también una migración de ERP y SCM para facilita la compartición de datos.

Contar con un DWH abrirá nuevas puertas a las capacidades de business intelligence, tan importantes en un negocio comercial como el vuestro. Cada vez son más los SaaS analíticos que se lanzan al mercado. Otro beneficio que tendrá el DWH en la nube respecto a su homólogo on premise, es la gestión de la seguridad.

Por el mismo motivo que se mencionaba anteriormente, la reducción de presupuestos y mala situación económica, nuevamente, todo suma puntos a favor de decidir ir a la nube. Probablemente el coste inicial de poner en marcha un DWH on premise, solo en cuanto a las implicaciones de inversión en hardware y en compra de licencias de SW, lo haría inviable.

Por tanto, nube: sí, pero recuerda, no escatimes esfuerzo en elegir al proveedor que mejor encaje con tus requerimientos.

2.1 Almacenamiento de datos en la nube frente al almacenamiento local

Cuando queremos comparar la eficiencia de un data warehouse en la nube frente a otro on premise, son varios los aspectos sobre los cuales debemos fijarnos:

- El coste asociado al tiempo y a los retrasos potenciales en la puesta en marcha del almacén de datos
- Los costes de almacenamiento y de computación
- Los beneficios de la elasticidad dinámica
- La externalización de la administración y la seguridad

Cuando una organización se encuentra evaluando un nuevo data warehouse, la primera opción a considerar es dónde quiere que se ubique su almacén de datos: bien en el centro de datos de la propia organización o en la nube mediante un software como servicio (SaaS).

El almacenamiento de datos tradicional on premise, como ya sabemos, es una tecnología madura y probada, diseñada mucho antes de que la nube se convirtiera en una plataforma viable. Con la rápida adopción del cloud computing, surge la necesidad de soluciones de almacenamiento de datos que puedan aprovechar al máximo lo que ofrece la nube. Vamos a realizar una serie de consideraciones clave para el almacenamiento de datos en la nube, al compararlo con los sistemas tradicionales on premise.

2.1.1 Evaluando el coste del tiempo

El despliegue de un almacén de datos convencional, como hemos anticipado, puede llevar por lo menos un año y dilatarse hasta un proyecto de varios años antes de que se extraiga un valor añadido de los datos. La agilidad de los negocios de hoy en día implica que los principales interesados que apoyan el proyecto y los principales habilitadores comerciales y técnicos responsables del éxito del mismo, podrían abandonar el equipo o la empresa antes de que el proyecto se ponga en marcha. Un ciclo tan largo también expone el proyecto a recesiones económicas, a la falta de ingresos en las empresas y al riesgo de no poner nunca en marcha el proyecto debido a la ampliación de su alcance.

Además, las soluciones in situ no están bien preparadas para manejar los datos semiestructurados tan frecuentes en la actualidad. Eso requiere añadir una plataforma, en muchas ocasiones open source, NoSQL, que agrega otra capa de complejidad y alarga la fase de implementación del nuevo data warehouse.

Si se hace bien, un almacén de datos en la nube puede estar en funcionamiento en semanas o en pocos meses. Por lo tanto, la mayor parte del tiempo requerido para su puesta en marcha puede aprovecharse para tareas más valiosas como extraer datos de las diversas fuentes corporativas y configurar una herramienta analítica de front-end para extraer información del data warehouse.

2.1.2 Los costes del almacenamiento y de computación

Los almacenes de datos on premise son caros en términos de hardware, software y administración de sistemas. Los costes de hardware pueden incluir las inversiones en los servidores, los dispositivos de almacenamiento adicionales, el espacio del centro de datos para alojar el hardware, una red de alta velocidad para acceder a los datos, la energía consumida y las fuentes de alimentación redundantes necesarias para mantener el sistema en funcionamiento, etc.

Si el data warehouse es de misión crítica, hay que añadir el coste de configuración del sistema de recuperación ante desastres. Las organizaciones de todo tipo, sobre todo los gobiernos y las grandes corporaciones, también suelen pagar cientos de miles de euros en licencias de software para su almacén de datos, así como en servicios añadidos. Cada usuario final adicional que deba usar el data warehouse dentro de la empresa, incluidos los clientes y proveedores a los que se les da acceso al almacén de datos, pueden aumentar significativamente dichos costes de licenciamiento. A esto hay que añadir el coste recurrente de los contratos anuales de soporte, que a menudo constituyen hasta el 20 % o más del precio de la licencia original. Además, un almacén de datos in situ necesita personal especializado en tecnologías de la información para desplegar y mantener el sistema. Esto crea un posible cuello de botella cuando surgen problemas y provoca que la responsabilidad del sistema recaiga en el cliente y no en el proveedor.

Un almacén de datos en la nube reemplaza el CapEx (capital expenditures) inicial y el coste recurrente de un sistema in situ por una simple tarifa basada en el uso, lo que se denomina OpEx (operational expenditures).

Las organizaciones pasan a pagar una cuota mensual basada en la cantidad de almacenamiento y recursos de computación que realmente utilizan en cada momento. Hablando en términos conservadores, según distintos analistas de mercado, el coste total anualizado de una solución de almacenamiento de datos en la nube puede ser una décima parte del coste de un sistema similar in situ.

2.1.3 Dimensionamiento, equilibrio y tuning

Para un rendimiento óptimo, un almacén de datos on premise debe ser modelado, dimensionado, equilibrado y ajustado, lo que requiere una importante inversión inicial junto con costes de mantenimiento y administración recurrentes. Esa puesta en marcha inicial suele incluir:

- Adquirir un número determinado de unidades centrales de procesamiento (CPUs) de una velocidad suficiente
- Comprar la cantidad necesaria de memoria
- Establecer el número y tamaño de los discos suficientes para la capacidad de almacenamiento requerida
- Contratar el ancho de banda de entrada/salida (E/S) por la cantidad máxima de datos que puedan ser transferidos en un momento dado
- Crear un modelo de datos personalizado que defina la estructura del almacén, los tipos de datos incluidos y la frecuencia de actualización

Al contar con un almacén de datos in situ, las organizaciones suelen dimensionar su sistema para un uso máximo, que puede representar sólo un pequeño período del año. Por ejemplo, una empresa puede necesitar toda la potencia del almacén de datos sólo al final de cada trimestre o año financiero. Pero debe pagar por esa capacidad máxima las 24 horas del día, todos los días del año, porque el sistema no se puede ampliar o reducir fácilmente. El almacenamiento elástico de datos en la nube ofrece dos ventajas fundamentales:

- Las complejidades y los costes asociados a la planificación de la capacidad y la administración -dimensionamiento y ajuste del sistema- están incluidos en la tarifa de suscripción.
- Lo mismo ocurre con el almacenamiento y el aprovisionamiento dinámico de los recursos para satisfacer las demandas de las cambiantes cargas de trabajo en períodos de uso máximo.

Esa es la gran ventaja de operar un data warehouse en la nube, que podemos disponer de la capacidad necesaria cuando se necesita. Pero no todas las cargas de trabajo presentan las mismas exigencias. Un almacén de datos en la nube debe ser muy granular en cuanto a qué recursos se asignan a qué usuarios y según las cargas de trabajo de cada momento.

2.1.4 Considerando los costes de preparación de datos y de ETL

Un data warehouse on premise debe extraer datos de todas o prácticamente todas las fuentes de datos disponibles en la organización. Luego, debe transformar esos datos para poder cargarlos en la estructura de datos, a

menudo rígida, dentro del sistema. Dado que estos procesos suelen consumir muchos recursos, para no entorpecer las actividades habituales de procesamiento en el data warehouse, lo más común es que la transformación de los datos deba ocurrir fuera de las horas normales de trabajo para evitar competir con otras tareas de procesamiento de datos. Este proceso suele ser todavía más complejo si los datos semiestructurados no se encuentran en forma de filas y columnas o cuando los datos presentan un alto volumen y una alta velocidad de cambio.

Las mejores soluciones de data warehouse en la nube pueden cargar datos semi estructurados directamente sin transformarlos. Estas soluciones pueden proporcionar acceso a datos nuevos hasta 50 veces más rápido que un almacén de datos tradicional. Además, el menor coste del almacenamiento cuasi ilimitado en la nube proporciona a los analistas de datos acceso a todos los datos históricos, en lugar de limitarlos a agregados periódicos de esos datos.



PARA SABER MÁS

A continuación, vamos a explicar cómo se puede optimizar una tubería de datos con un caso real.

DoubleDown es un estudio que desarrolla juegos en línea y que decidió añadir un sistema NoSQL a su pipeline de datos para preparar estos datos previamente a cargarlos en el data warehouse corporativo. Pero este enfoque implicaba que el registro de eventos diarios de DoubleDown requería largos tiempos de procesamiento. Hay que ser conscientes de la ingente cantidad de datos que una empresa como esta genera al tener millones de usuarios online, haciendo clic con su ratón sobre la pantalla del juego docenas de veces cada hora. La compañía no podía acceder a los datos del día hasta muy avanzado el día siguiente. Es decir, estamos hablando de más de 24 horas para poder explotar los datos, lo que en un negocio tan dinámico como los juegos, apuestas y casinos online no es asumible. Peor aún, si uno de sus clusters de servidores se caía, la compañía perdía una parte importante de los datos.

Por la grave situación descrita, DoubleDown decidió optar por un sistema que permitía cargar directamente sus datos semiestructurados sin transformarlos primero, haciendo que esos datos estuvieran disponibles inmediatamente para consultas. Esto mejoró la calidad y el rendimiento de su tubería de datos al hacer llegar los datos a los analistas de marketing casi 100 veces más rápido (en 15 minutos frente a más de 24 horas) eliminando casi todos los fallos frecuentes en el pipeline de datos de la compañía, proporcionando a los analistas la granularidad completa de los datos en lugar de agregados periódicos y reduciendo el coste de operación y mantenimiento de la tubería de datos de DoubleDown en un 80%.

Los analistas de DoubleDown tienen ahora acceso inmediato a los datos de sus clientes y productos para tomar decisiones más rápidas y basadas en datos.



ENLACE DE INTERÉS

En el siguiente enlace se explica cómo justificar los costes de data warehouse

<http://carlosproal.com/dw/dw10.html>

2.1.5 Añadir el coste de las herramientas analíticas especializadas

Como sabemos, los almacenes de datos tradicionales in situ no están preparados para manejar el volumen, la variedad y la velocidad de los datos actuales, lo que muchas veces se abrevia bajo el concepto de big data. Como resultado, las organizaciones en demasiadas ocasiones están obligadas a operar dos plataformas de datos en paralelo: por un lado, un almacén de datos SQL empresarial in situ para el almacenamiento de datos relacionales tradicionales y, por otro lado, una gran plataforma de datos NoSQL, que puede funcionar en una infraestructura propia o en la nube, para el almacenamiento de datos no relacionales.

Lamentablemente, estos sistemas más modernos añaden mucha complejidad a la gestión y requieren herramientas y conocimientos especializados que no son tan frecuentes como ocurre con las herramientas y los conocimientos de SQL. Al fin y al cabo, el lenguaje SQL ha existido desde hace décadas, mientras que los sistemas NoSQL son relativamente nuevos.

La solución ideal de almacenamiento de datos en la nube ofrece lo mejor de ambos mundos: la flexibilidad de integrar datos relacionales y no relacionales junto con el soporte de las herramientas SQL fácilmente disponibles y las habilidades para consultar esos datos.

Cuando se analiza el mercado de fabricantes y proveedores para implementar un nuevo data warehouse, hay que considerar el coste y la disponibilidad de las habilidades y la experiencia necesarias para administrar el almacén de datos, así como las muchas herramientas analíticas y de otro tipo que se utilizan junto con un almacén de datos.

2.1.6 Hacer concesiones para la escalabilidad y la elasticidad

Los almacenes de datos convencionales son propensos a la ralentización y el colapso de los sistemas, ya que los usuarios y los procesos compiten por recursos limitados. Estos sistemas suelen integrar el almacenamiento y la computación en un solo cluster de servidores, lo que hace que sea costoso aumentar una de las características del sistema sin aumentar la otra.


Las nuevas soluciones de almacenamiento de datos construidas en la nube proporcionan un almacenamiento y un cómputo virtualmente ilimitados aportando una ventaja añadida a los enfoques previos, que es que los data warehouse ahora pueden escalar el almacenamiento de forma separada al cómputo. Lo ideal sería que el data warehouse en la nube escalara de tres maneras:

- **Recursos de almacenamiento:** Suele ser el tipo de escalado más sencillo, porque el almacenamiento en la nube es intrínsecamente escalable, se puede ajustar fácilmente la cantidad de almacenamiento para satisfacer las necesidades cambiantes.
- **Recursos de cómputo:** Los recursos utilizados para procesar las cargas de datos y las consultas deben ser fácilmente ampliables o reducibles, en cualquier momento, ya que el número y la intensidad de las cargas de trabajo cambian.
- **Usuarios y cargas de trabajo (conurrencia):** Las soluciones con recursos informáticos fijos se ralentizan a medida que aumentan los usuarios y las cargas de trabajo frente a la nube que debe facilitar el escalar en horizontal o vertical para satisfacer del mejor modo posible los incrementos en los picos de trabajo.

Las organizaciones a menudo se ven obligadas (por cuestiones técnicas, de negocio o legales) a replicar los datos en mercados separados, a trasladar algunas cargas de trabajo fuera de las horas normales de trabajo y a poner en cola a los usuarios para preservar el rendimiento. Sólo la nube puede permitir que un almacén de datos se amplíe agregando recursos de computación dedicados de cualquier magnitud, prestando soporte a un número casi infinito de usuarios o cargas de trabajo que acceden a una sola copia de los datos, sin afectar el rendimiento de los demás usuarios.

Elegir una solución de nube que separe el almacenamiento de la computación es la mejor opción y la que tiene más recorrido a futuro, para que ambos puedan escalar fácilmente y de forma independiente uno del otro, para mantener los costes bajos y no desperdiciar ningún recurso. La solución elegida también debería escalarse en forma horizontal, para soportar más usuarios y cargas de trabajo sin perjudicar el rendimiento.

LA ESCALA Y LA ELASTICIDAD



El almacén de datos ideal debería escalar de tres maneras.

Fuente: Elaboración propia

2.1.7 Disminuyendo los retrasos y el tiempo de inactividad

Muchas empresas con soluciones in situ presentan dos quejas principales. Deben esperar horas o, incluso, más de un día, antes de que los datos recogidos el día anterior estén en el data warehouse disponibles para su explotación. También puede ser que deban esperar mucho tiempo para que una consulta compleja se ejecute en un gran conjunto de datos. En algunos casos, múltiples procesos concurrentes pueden congelar o hacer que el sistema se bloquee, prolongando las demoras y el tiempo de inactividad.

Con un almacenamiento y recursos de computación virtualmente ilimitados, las soluciones de almacenamiento de datos en la nube, diseñadas de forma dinámica y elástica, están mejor equipadas para escalar, pero también para desescalar e, incluso, para desmantelarlas cuando dejan de ser necesarias. Sin embargo, disminuir los retrasos y eliminar los tiempos de inactividad no deseados requiere más que simplemente aumentar los recursos del sistema. Las mejores soluciones racionalizan los pipelines de datos y almacenan los datos para que las consultas se ejecuten de forma más eficiente sin necesidad de ajustes manuales.

Una solución de cloud data warehouse óptima debe abordar todos estos tipos de problemas de rendimiento para minimizar el tiempo de inactividad. La rapidez con la que se pueda acceder a los datos corporativos y a su análisis puede afectar significativamente a las operaciones de la compañía y a la capacidad para mantener una ventaja competitiva.

2.1.8 Considerando los costes de los aspectos de seguridad

Un único fallo de seguridad puede convertirse rápidamente en una pesadilla que estropea la imagen de cualquier empresa y provoca la pérdida de mucho dinero y multas elevadas de los organismos reguladores como las agencias de protección de datos. Aunque la nube, en muchas ocasiones, se considera como una tecnología de alto riesgo de seguridad, con un proveedor confiable puede ser más segura que un centro de datos propio.

Si una compañía opta por un almacén de datos en sus instalaciones, ella es la única responsable de asegurar los datos confidenciales, lo que supone prestar una atención cuidadosa y constante a la protección mediante firewalls, protocolos de seguridad, cifrado de datos, tanto en el almacenamiento en reposo y como en el tránsito de las telecomunicaciones, las funciones y los privilegios de los usuarios y la supervisión y adaptación a las nuevas amenazas a la seguridad (ataques denominados zero day y otros). La seguridad efectiva de los datos es compleja y costosa de aplicar, especialmente en lo que respecta a los recursos humanos. Las medidas de seguridad mal implementadas exponen a un coste aún mayor cuando los riesgos de seguridad impactan en la empresa.

Dado que los proveedores de almacenamiento de datos en la nube sirven a varios clientes, cuentan con la experiencia y los recursos necesarios para promover la seguridad de los almacenes de datos extremo a extremo y con gran solidez, cumpliendo con los estándares más rigurosos. Elegir un proveedor que garantice un cifrado robusto, de extremo a extremo, que asegure los datos, tanto en reposo como en tránsito, es una condición mínima a la hora de implementar un data warehouse en la nube.

2.1.9 Pagar por la protección y recuperación de datos

Los almacenes de datos on premise son vulnerables a la pérdida de datos por fallos en los equipos, cortes o subidas de tensión, robos o vandalismo y desastres naturales (incendios, inundaciones, terremotos, etc.). Para proteger los datos, se deben hacer copias de seguridad regularmente y almacenarlas en una ubicación remota. También es necesario una fuente de alimentación de backup para evitar la pérdida de datos y asegurar que el data warehouse esté siempre disponible para procesar los datos y las consultas entrantes. Si se produce un desastre, se necesitará personal cualificado para recuperar los datos, utilizando las copias de seguridad más recientes. Si el almacén de datos es de misión crítica, es posible que también se requiera un sitio de recuperación de desastres separado geográficamente (un centro de datos adicional) junto con el software, las licencias y los procesos para

garantizar la conmutación automática cuando se detecta un error, de modo que no se produzca una interrupción del servicio.

La nube proporciona una solución ideal para la protección y recuperación de datos. Por su naturaleza, almacena los datos fuera de las instalaciones del cliente. Algunas soluciones basadas en la nube hacen automáticamente una copia de seguridad de los datos en dos o más lugares físicos separados. Si los centros de datos están aislados geográficamente, también proporcionan una recuperación ante desastres implícita.


Los centros de datos de la nube tienen fuentes de alimentación redundantes, por lo que se mantienen en funcionamiento incluso durante cortes de energía prolongados. Los proveedores de la nube pueden ofrecer estas salvaguardas a un coste mucho más bajo que lo que cuesta a cada empresa individualmente implementar toda esa infraestructura, porque se está distribuyendo el coste entre cientos o miles de clientes.



SABÍAS QUE...

Cuando una empresa no desea administrar sus propias copias de seguridad de los datos, debe asegurarse de preguntar a su potencial proveedor de data warehouse en la nube cómo configura y cómo funciona este tipo de servicio. Asimismo, si una empresa necesita protección para la recuperación ante desastres, debe confirmar que la arquitectura del proveedor utiliza centros separados geográficamente.

También se debe verificar si el proveedor elegido ofrece su solución a través de nubes de múltiples tipos, por ejemplo, Azure de Microsoft y AWS de Amazon simultáneamente, para que en caso de que un desastre lo requiera, se pueda cambiar a una instancia del data warehouse en otra nube.



EJEMPLO PRÁCTICO

Una pequeña Caja de Ahorros Rural ha dependido hasta la fecha de la plataforma informática que subcontractaba a un importante banco. Esta Caja Rural nunca ha podido crear su propia estrategia de sistemas porque el Banco de España le exige por normativa que deben disponer de dos centros de datos separados entre ellos por 300 km como mínimo.

Esta caja difícilmente podría permitirse uno de ellos, como para poder invertir en crear dos. Por este motivo, ha tenido que venir subcontractando dicha actividad.

La realidad es que en un mercado tan dinámico como el actual, utilizar un sistema que no está diseñado a la medida de las necesidades de uno provoca que el negocio no funcione correctamente.

Los directores quieren encontrar una solución a ello.

¿Cómo lo podrías solucionar?

Solución

Gracias a la nube hoy en día es mucho más sencillo y, sobre todo, mucho más barato, poder disponer de réplicas de nuestro centro de datos en distintas ubicaciones geográficas para que incluso, el peor de los desastres naturales como un gran terremoto, no pudiese acabar con la continuidad de negocio.

Por tanto, la solución basa por identificar un proveedor que sea capaz de mostrarnos que dispone de una arquitectura en cada uno de sus centros de datos y entre ellos que cumpla con la normativa que exige el Banco de España a las entidades de crédito y así poder comenzar a construir nuestro propio sistema de información.

RESUMEN

En este apartado hemos revisado los conceptos básicos sobre lo que es un data warehouse, sus elementos, cómo es su arquitectura. También se ha recalcado la importancia que tiene para alcanzar un data mining exitoso.

Los distintos esquemas con sus ventajas, desventajas y principales características han sido comparados.

Hay que tomar muy en cuenta todos estos factores cuando realizamos una implementación, ya que unos funcionarían mejor según ciertos casos de análisis que se pretendan abordar.

Es de suma importancia la fidelidad de los datos y la limpieza óptima de los mismos y, aunque nos consuma bastante tiempo, su rol es muy importante para obtener los mejores resultados posibles.